

第6次作业 理论题

决策树

1. 考虑如下数据集，其中三个二元输入属性 (A_1, A_2, A_3) 和一个二元输出 y

样 例	A_1	A_2	A_3	输出 y
x_1	1	0	0	0
x_2	1	0	1	0
x_3	0	1	0	0
x_4	1	1	1	1
x_5	1	1	0	1

在这些数据上使用下图所示的算法学习一颗决策树。说明在每个结点上选择分裂属性时所做的计算。

停止条件 ←

```

function DECISION-TREE-LEARNING(examples, attributes, parent_examples) returns
a tree
    if examples is empty then return PLURALITY-VALUE(parent_examples)
    else if all examples have the same classification then return the classification
    else if attributes is empty then return PLURALITY-VALUE(examples)
    else
         $A \leftarrow \operatorname{argmax}_{a \in \text{attributes}} \text{IMPORTANCE}(a, \text{examples})$ 
        tree ← a new decision tree with root test A
        for each value  $v_k$  of A do
            exs ← {  $e : e \in \text{examples} \text{ and } e.A = v_k$  }
            subtree ← DECISION-TREE-LEARNING(exs, attributes - A, examples)
            add a branch to tree with label ( $A = v_k$ ) and subtree subtree
        return tree
    
```

图 18.5 决策树学习算法。函数 IMPORTANCE 在 18.3.4 节描述，函数 PLURALITY-VALUE 选择样例集中最常见的输出值，随机打破僵局

知识点

集合的信息熵 Entropy $H(S) = -\sum p_i \log_2 p_i$

对于二元分类，若 $y=1$ 有 p 个， $y=0$ 有 n 个

则熵为 $B(q) = -[q \log_2 q + (1-q) \log_2 (1-q)]$ 其中 $q = \frac{p}{p+n}$

剩余熵 Remainder

按属性 A 分裂后子集的加权平均熵

$$\text{Remainder}(A) = \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$$

信息增益 Gain

分裂前后熵的减量 $\text{Gain}(A) = H(S) - \text{Remainder}(A)$

1. 解

① 算根节点初始熵

$Y=1$ 的个数: 2 (x_4, x_5)

$Y=0$ 的个数: 3 (x_1, x_2, x_3)

总占比 $q = \frac{2}{5} = 0.4$

$$H(S) = B(0.4) = -(0.4 \log_2 0.4 + 0.6 \log_2 0.6) \approx 0.971$$

② 算各属性的信息增益, 选择根节点分裂属性

A_1 : $A_1=1$ 时 样本 $\{x_1, x_2, x_4, x_5\}$ 输出 Y 为 $\{0, 0, 1, 1\}$

正反例各2个 $H = B(0.5) = 1$

$A_1=0$ 时 样本 $\{x_3\}$ 输出 Y 为 $\{0\}$ 纯净集 $H=0$

$$\Rightarrow \text{Remainder}(A_1) = \frac{4}{5} \times 1 + \frac{1}{5} \times 0 = 0.8$$

$$\text{Gain}(A_1) = 0.971 - 0.8 = 0.171$$

A_2 : $A_2=1$ 时 样本 $\{x_3, x_4, x_5\}$ 输出 Y 为 $\{0, 1, 1\}$

2正1反 $H = B(\frac{2}{3}) \approx 0.918$

$A_2=0$ 时 样本 $\{x_1, x_2\}$ 输出 Y 为 $\{0, 0\}$ 纯净集 $H=0$

$$\Rightarrow \text{Remainder}(A_2) = \frac{3}{5} \times 0.918 + \frac{2}{5} \times 0 \approx 0.551$$

$$\text{Gain}(A_2) = 0.971 - 0.551 = 0.420$$

A_3 : $A_3=1$ 时 样本 $\{x_2, x_4\}$ 输出 Y 为 $\{0, 1\}$

1正1反 $H = 1.0$

$A_3=0$ 时 样本 $\{x_1, x_3, x_5\}$ 输出 Y 为 $\{0, 0, 1\}$

1正2反 $H = B(\frac{1}{3}) \approx 0.918$

$$\Rightarrow \text{Remainder}(A_3) = \frac{2}{5} \times 1 + \frac{3}{5} \times 0.918 \approx 0.951$$

$$\text{Gain}(A_3) = 0.971 - 0.951 = 0.020$$

综上 $\text{Gain}(A_2)$ 最大, 根节点选 A_2 进行分裂

③ 递归处理子分支

对节点 A_2

分支 $A_2=0$ 样本 $\{x_1, x_2\}$ 输出 Y 为 $\{0, 0\}$

满足 all examples have the same classification, 直接返回叶子节点 0

分支 $A_2=1$ 样本 $\{x_3, x_4, x_5\}$ 输出 Y 为 $\{0, 1, 1\}$

还不纯净, 从剩余属性 $\{A_1, A_3\}$ 中再选1个

此时 $H(S') = B(\frac{2}{3}) \approx 0.918$

在 $A_2=1$ 子集中

A_1 : $A_1=1$ 样本 $\{x_4, x_5\}$ 输出 Y 为 $\{1, 1\}$ $H=0$

$A_1=0$ 样本 $\{x_3\}$ 输出 Y 为 $\{0\}$ $H=0$

$$\Rightarrow \text{Remainder}(A_1) = 0$$

$$\text{Gain}(A_1) = 0.971 - 0 = 0.971$$

A_3 : $A_3=1$ 样本 $\{x_4\}$ 输出 Y 为 $\{1\}$ $H=0$

$A_3=0$ 样本 $\{x_3, x_5\}$ 输出 Y 为 $\{0, 1\}$ $H = B(0.5) = 1$

$$\Rightarrow \text{Remainder}(A_3) = \frac{1}{3} \times 0 + \frac{2}{3} \times 1 \approx 0.667$$

$$\text{Gain}(A_3) = 0.918 - 0.667 = 0.251$$

综上 $\text{Gain}(A_1)$ 最大, 节点 A_2 选 A_1 进行分裂

④ 决策树的构建

属性 A_2

0 / \ 1

分类0 属性 A_1

0 / \ 1

分类0 分类1

决策图

2. 决策图是决策树的泛化, 它允许结点(即, 用作分裂的属性)有多个父结点, 而不仅仅只有一个。但结果图必须仍然是无圈图。现在考虑三个二元输入属性的 XOR 函数。其定义是: XOR 产生值 1, 当且仅当奇数个输入属性具有值 1。

异或


- a. 画一个表示 3-输入函数 XOR 的、最小体积的决策树。
b. 画一个表示 3-输入函数 XOR 的、最小体积的决策图。

真值表

A_1	A_2	A_3	XOR
0	0	0	0
0	0	1	1
0	1	0	1
0	1	1	0
1	0	0	1
1	0	1	0
1	1	0	0
1	1	1	1

易知, 任何单一属性的信息增益为 0
故必须看完所有属性才能得出结论

(a) XOR 必须穷举 8 种组合, 没有可以合并的路径




故为完全二叉树

体积 = 15 个节点

对于 n 位 XOR,

决策树节点数呈指数增长 ($2^{n+1}-1$)

(b) XOR 的本质是奇偶校验 (Parity)



体积 = 7 个节点

每层只需 2 个状态节点, 规模线性增长 ($3n+1$)

线性激活函数的局限性

层级坍缩


3. 假设你有一个具有线性激活函数的神经网络，即对于每个神经元单元，其输出是其输入加权和的某个常数 c 倍。

(1) 假设该网络有一个隐藏层。对于给定的权重赋值 w ，请写出输出层单元值关于权重 w 和输入层 x 的函数方程，并要求方程中不得显式提及隐藏层的输出值。并证明：存在一个没有隐藏单元的网络可以计算出完全相同的函数。

(2) 重复第 1 小题中的计算，但这次针对具有任意数量隐藏层的网络。

(3) 假设一个具有单隐藏层和线性激活函数的网络，其输入节点数为 n ，输出节点数为 n ，隐藏节点数为 h 。如果按照第 1 小题的方法将其转换为一个没有隐藏层的网络，总权重数量会发生什么变化？请特别讨论当 $h \ll n$ 时的情况。

(1) 单隐藏层



因此，存在一个没有隐藏层的网络
可以计算完全相同的函数

$$h = c(W_1 x + b_1)$$

$$y = c(W_2 h + b_2)$$

$$y = c[W_2 \cdot c(W_1 x + b_1) + b_2]$$

$$= (c^2 W_2 W_1) x + (c^2 W_2 b_1 + b_2)$$

$$\text{令 } W' = c^2 W_2 W_1 \quad \text{令 } b' = c^2 W_2 b_1 + b_2$$

$$\text{则 } y = W' x + b'$$

(2) 任意数量隐藏层

结论成立

证明：数学归纳法

假设有 k 层隐藏层，每层都是线性映射 $L_i(z) = c(W_i z + b_i)$

整个网络的输出为这些线性映射的复合： $y = L_{out}(L_k(\dots L_1(x)\dots))$

化简得： $y = (c^{k+1} W_{out} W_k \dots W_1) x + \text{偏置常数项}$

线性函数的复合仍是线性函数

若 $f(x) = ax + b$ 且 $g(x) = cx + d$ ，则 $g(f(x)) = c(ax + b) + d = (ca)x + cb + d$

在神经网络中，这意味着多层网络在数学上等价于单层网络

(3) 权重数量变化

① 单隐藏层网络

输入层 $\rightarrow$ 隐藏层： $n \times h$ 个权重

隐藏层 $\rightarrow$ 输出层： $h \times n$ 个权重

总权重数： $2nh$

特别地 当 $h \ll n$ 时， $2nh \ll n^2$

② 无隐藏层网络

输入层 $\rightarrow$ 输出层： $n \times n$ 个权重

总权重数： n^2

结论：① 参数规模增加：从小隐藏层转无隐藏层时，总权重剧增

② 表达能力限制：转换后网络的秩被限制在 h