

概率论

概率: 分布 → 数据
统计: 数据 → 分布

$$A_n^m = \frac{n!}{(n-m)!}$$
$$C_n^m = \frac{A_n^m}{m!} = \frac{n!}{m!(n-m)!}$$

基本概念

事件 关系 ① $A \subset B$ ② $A=B$ ③ $P(A \cup B) = P(A) + P(B)$ ④ $P(A \cap B) = P(A)P(B)$

运算 ① 和 $A+B = A \cup B$ ② 积 $AB = A \cap B$ ③ 差 $A-B = A \cap B^c$

④ 互斥 $A \cap B = \emptyset$ ⑤ 对立 $A \cup B = S$ 且 $A \cap B = \emptyset$ $\bar{A}/A^c$

⑥ $A \cup B = B \cup A$ $A \cap (B \cap C) = (A \cap B) \cap C$ $(A \cup B) \cap C = (A \cap C) \cup (B \cap C)$

⑦ $\bigcup_{j=1}^n A_j = \overline{\bigcap_{j=1}^n \bar{A}_j}$ $\bigcap_{j=1}^n A_j = \overline{\bigcup_{j=1}^n \bar{A}_j}$ 德摩根

频率 定义 $f_n(A) = \frac{n_A}{n}$

性质 ① $\forall A, 0 \leq f_n(A) \leq 1$ ② $f_n(S) = 1$

③ $A_1, \dots, A_k$ 两两不相容 $f_n(\bigcup_{j=1}^k A_j) = \sum_{j=1}^k f_n(A_j)$

概率 定义 统计性/公理性 (非负+规范+可列可加)

性质 ① $P(\bigcup_{j=1}^k A_j) = \sum_{j=1}^k P(A_j)$

② $P(A) = 1 - P(\bar{A})$

③ $A \supset B$ 时 $P(A-B) = P(A) - P(B)$

$P(A) = P(B) + P(A-B)$

④ $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

$P(\bigcup_{j=1}^{\infty} A_j) = \sum_{j=1}^{\infty} P(A_j) - \sum_{i < j} P(A_i \cap A_j) + \dots + (-1)^{n+1} P(A_1 \cap \dots \cap A_n) + \dots$

等可能 性质 有限+等可能

古典概型

典例 红球白

① 放回抽样 $P = (\frac{a}{a+b})^k$

② 不放回抽样 $P = \frac{C_a^k C_{b-a}^{n-k}}{C_{a+b}^n}$

超几何分布 $P = \frac{C_a^k C_{b-a}^{n-k}}{C_{a+b}^n}$

③ 抽签公平(不放回): 第k个抽到红 $P(A_k) = \frac{a(a+b-1) \dots (a+b-k+1)}{(a+b)!}$

④ 生日重合 (n 个人, N 个): 恰有 n 个盒子各有一球 $P(A) = \frac{N(N-1)(N-2) \dots (N-n+1)}{N^n}$
至少有一人生日重合 $1 - P(A)$

$$C_n^k = \frac{n!}{k!(n-k)!} \text{ 或 } \binom{n}{k}$$

$$\max\{0, n-b\} \leq k \leq \min\{a, n\}$$

条件概率 定义 $P(B|A) = \frac{P(AB)}{P(A)} = \frac{n_{AB}}{n_A}$

性质 ① $P(A|C) \geq 0$ ② $P(S|C) = 1$ ③ $P(B|C) = 1 - P(\bar{B}|C)$

④ $A \supset B$ 时 $P(A|C) \geq P(B|C)$

⑤ $P(A \cup B|C) = P(A|C) + P(B|C) - P(AB|C)$

⑥ $P(C|A \cup B) = \frac{P(C \cap A \cup B)}{P(A \cup B)}$

⑦ $P(AB) = P(A|B)P(B) = P(B|A)P(A)$

$P(A_1 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1 A_2) \dots P(A_n|A_1 \dots A_{n-1})$

全概率公式 S 的完备事件组 ① $B_i B_j = \emptyset$ ② $B_1 \cup B_2 \cup \dots \cup B_n = S$

全概率公式 $P(A) = \sum_{j=1}^n P(B_j)P(A|B_j)$

贝叶斯/逆概率公式 $P(B_k|A) = \frac{P(B_k)P(A|B_k)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$

事件独立性 定义 ① A 与 B 相互独立 $\Leftrightarrow P(AB) = P(A)P(B)$

② $A_1, A_2, \dots, A_n$ 相互独立 $\Leftrightarrow$

设 $A_1, A_2, \dots, A_n$ 为 n 个随机事件, 对 $2 \leq k \leq n$, 均有 $P(A_1, A_2, \dots, A_k) = \prod_{j=1}^k P(A_j)$

性质 ① $P(B|A) = P(B)$

② A 与 B, A 与 $\bar{B}$, $\bar{A}$ 与 B 相互独立

区分: ABC 两两独立

$P(AB) = P(A)P(B)$

$P(AC) = P(A)P(C)$

$P(BC) = P(B)P(C)$

ABC 相互独立

$P(ABC) = P(A)P(B)P(C)$

$P(AC) = P(A)P(C)$

$P(BC) = P(B)P(C)$

$P(ABC) = P(A)P(B)P(C)$

$$C_2^3 + C_3^3 = 4$$

随机变量及其概率分布

离散型 定义 概率分布列/律 $P\{X=x_k\} = p_k$

性质 ① $p_k \geq 0$ ② $\sum_{k=1}^{\infty} p_k = 1$

典例 ① 0-1 两点分布 $X \sim B(1, p)$ 或 $0-1(p)$

$P\{X=k\} = p^k(1-p)^{1-k} \quad k=0, 1$

② 二项分布 $X \sim B(n, p)$

$P\{X=k\} = C_n^k p^k(1-p)^{n-k} \quad k=0, 1, 2, \dots, n$

③ 泊松分布 $P(\lambda)$ $k=0, 1, 2, \dots, \infty$

$P\{X=k\} = \frac{\lambda^k e^{-\lambda}}{k!}$ 当 λ 很大时 $B(n, p)$ 近似为 $\lambda=np$

④ 超几何分布 $H(n, a, N)$

$P\{X=k\} = \frac{C_a^k C_{N-a}^{n-k}}{C_N^n} \quad k=0, 1, \dots, n$

⑤ 几何分布 (首次成功) $G(p)$

$P\{X=k\} = p(1-p)^{k-1} \quad k=0, 1, \dots, \infty$

⑥ 帕斯卡/负二项分布 $NB(r, p)$ (第 r 次成功)

$P\{X=k\} = C_{k-1}^{r-1} p^r (1-p)^{k-r} \quad k=r, r+1, \dots, \infty$

连续型 定义 概率密度函数 $f(x) = P\{X=x\}$

性质 ① $0 \leq f(x) < \infty$, 且 $\int_{-\infty}^{\infty} f(x) dx = 1$ [a, b]

② $f(x)$ 单调不减 $\Leftrightarrow 0 \leq P\{x_1 < X < x_2\} = F(x_2) - F(x_1)$

③ $f(x)$ 右连续, 即 $F(x_0) = F(x_0+)$ 连续

④ 某点概率 = 右极限 - 左极限 点

典例 ① 均匀分布 $X \sim U(a, b)$

$f(x) = \begin{cases} \frac{1}{b-a} & x \in (a, b) \\ 0 & \text{其他} \end{cases} \Rightarrow F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a < x < b \\ 1 & x \geq b \end{cases}$

② 指数分布 $X \sim E(\lambda)$

$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases} \Rightarrow F(x) = \int_{-\infty}^x f(t) dt = \begin{cases} 1 - e^{-\lambda x} & x \geq 0 \\ 0 & x < 0 \end{cases}$

③ 正态分布 $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \Rightarrow F(x) = \int_{-\infty}^x \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt$
($-\infty < x < +\infty$) 其中 $-\infty < \mu < +\infty, \sigma > 0$

④ 标准正态分布

$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \quad (-\infty < x < +\infty) \Rightarrow \Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$

随机变量函数的分布

$Y=g(X)$ 求法: 离散型 $\{Y=y_k\} \Leftrightarrow \{X=x_k\} \quad P\{Y=y_k\} = P\{X=x_k\}$
连续型 $\{Y=y\} \Leftrightarrow \{g(x)=y\} \Leftrightarrow \{x \in D_y\} \quad F_Y(y) = P\{Y \leq y\} = P\{X \in D_y\}$

定理 若 $y=g(x)$ 为处处可导的严格单调函数, 记 $y=g(x)$ 反函数为 $x=h(y)$

Y 的密度函数为 $f_Y(y) = \begin{cases} f_X(h(y)) |h'(y)| & y \in D \\ 0 & y \notin D \end{cases}$

定义 F 的反函数 $\forall 0 < y < 1$ 令 $F_1^{-1}(y) = \sup\{x: F(x) \leq y\}$

性质 ① $F_1^{-1}(y)$ 为 y 的单调不减函数

② $F(F_1^{-1}(y)) \leq y$ 且若 F 在 $F_1^{-1}(y)$ 处连续, 则 $F(F_1^{-1}(y)) = y$

③ $F_1^{-1}(y) \leq x$ 充要条件为 $y \leq F(x)$

故当 $0 < y < 1$ 时 $P\{Y \leq y\} = P\{F(X) \leq y\} = P\{X \leq F_1^{-1}(y)\} = F(F_1^{-1}(y)) = y$


概率密度函数 $f(x)$ $\forall x \in R, F(x) = \int_{-\infty}^x f(t) dt$

① $f(x) \geq 0$

② $\int_{-\infty}^{\infty} f(x) dx = 1$

③ $\forall x_1, x_2 \in R, (x_1 < x_2) \quad P\{x_1 < X < x_2\} = F(x_2) - F(x_1) = \int_{x_1}^{x_2} f(t) dt$
 $\Rightarrow$ 某点概率 $P(x_1) = 0$


④ 在连续点 x 有 $F(x) = f(x)$ 点连续无间断点



① $E(X) = \mu$

② $P\{X > t+1 | X > t\} = e^{-\lambda} = P\{X > t\}$

③ 关于 $x=\mu$ 对称
④ $\max_{-\infty < x < +\infty} f(x) = \frac{1}{\sigma\sqrt{2\pi}}$
⑤ $\lim_{|x| \rightarrow +\infty} f(x) = 0$



① $\forall x, \Phi(x) = 1 - \Phi(-x)$

② $X \sim N(\mu, \sigma^2) \quad \forall a < b \quad P(a < X < b) = \Phi(\frac{b-\mu}{\sigma}) - \Phi(\frac{a-\mu}{\sigma})$

③ $P\{|X-\mu| < k\sigma\} = \Phi(\frac{k}{\sigma}) - \Phi(-\frac{k}{\sigma}) = 2\Phi(\frac{k}{\sigma}) - 1$

④ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑤ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑥ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑦ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑧ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑨ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑩ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑪ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑫ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑬ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑭ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑮ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑯ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑰ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑱ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑲ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

⑳ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉑ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉒ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉓ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉔ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉕ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉖ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉗ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

㉘ $\Phi(x) = \frac{1}{2} + \frac{1}{\pi} \arctan \frac{x}{\sigma}$

多元随机变量及其概率分布

离散型

- ① 联合分布 $P\{X=x_i, Y=y_j\} = p_{ij}$
② 边缘分布 $P\{X=x_i\} = \sum_j p_{ij}$ $P\{Y=y_j\} = \sum_i p_{ij}$
③ 条件分布 当 $P\{Y=y_j\} > 0$ 时, $P\{X=x_i|Y=y_j\} = \frac{p_{ij}}{p_{.j}}$
当 $P\{X=x_i\} > 0$ 时, $P\{Y=y_j|X=x_i\} = \frac{p_{ij}}{p_{i.}}$

分布函数

$$F(x,y) = P\{X \leq x, Y \leq y\}$$

- 性质: ① 给定 $x=x_i$ 时, $F(x,y)$ 关于 y 单调不减
② $0 \leq F(x,y) \leq 1$ $F(x,+\infty) = 1$
且 $F(x,-\infty) = F(-\infty,y) = F(-\infty,-\infty) = 0$
③ $F(x,y) = F(y,x)$ $F(x,y) = F(y,x)$
④ 当 $x_i > x_j, y_i > y_j$ 时
 $F(x_i,y_i) - F(x_i,y_j) - F(x_j,y_i) + F(x_j,y_j) = P\{x_j < X \leq x_i, y_j < Y \leq y_i\} \geq 0$

密度函数

$$\forall x,y \in R \text{ 有 } f(x,y) = \frac{\partial^2 F(x,y)}{\partial x \partial y}$$

- ① $f(x,y) \geq 0$
② $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x,y) dx dy = F(+\infty, +\infty) = 1$
③ 在 $f(x,y)$ 连续点处有 $\frac{\partial^2 F(x,y)}{\partial x \partial y} = f(x,y)$
④ (X,Y) 落在 xOy 平面任一区域 D 的概率 $P\{(X,Y) \in D\} = \iint_D f(x,y) dx dy$

连续型

① 联合分布

$$F(x,y) = P\{X \leq x, Y \leq y\}$$

- 性质: ① 给定 $x=x_i$ 时, $F(x,y)$ 关于 y 单调不减
② $0 \leq F(x,y) \leq 1$ $F(x,+\infty) = 1$
且 $F(x,-\infty) = F(-\infty,y) = F(-\infty,-\infty) = 0$
③ $F(x,y) = F(y,x)$ $F(x,y) = F(y,x)$
④ 当 $x_i > x_j, y_i > y_j$ 时
 $F(x_i,y_i) - F(x_i,y_j) - F(x_j,y_i) + F(x_j,y_j) = P\{x_j < X \leq x_i, y_j < Y \leq y_i\} \geq 0$

② 边缘分布

$$F_X(x) = F(x,+\infty) \quad F_Y(y) = F(+\infty, y)$$

③ 条件分布

$$F_{Y|X}(y|x) = \lim_{\delta \rightarrow 0} P\{Y \leq y | x < X \leq x+\delta\}$$

$$\text{离散 } F_{Y|X}(y|x_i) = P\{Y \leq y | X=x_i\}$$

④ 二元均匀分布

⑤ 二元正态分布 $(X,Y) \sim N(\mu_1, \mu_2; \sigma_1^2, \sigma_2^2; \rho)$

$$f_X(x) = \int_{-\infty}^{+\infty} f(x,y) dy$$

$$f_{Y|X}(y|x) = \frac{f(x,y)}{f_X(x)} \quad (-\infty < y < +\infty)$$

$$f(x,y) = \begin{cases} \frac{1}{D \text{ 的面积}} & (x,y) \in D \\ 0 & \text{其他} \end{cases} \quad P\{(X,Y) \in D\} = \frac{D \text{ 的面积}}{D \text{ 的面积}}$$

$$f_X(x) = \frac{1}{\sigma_1 \sigma_2} e^{-\frac{(x-\mu_1)^2}{2\sigma_1^2}} \quad f_Y(y) = \frac{1}{\sigma_1 \sigma_2} e^{-\frac{(y-\mu_2)^2}{2\sigma_2^2}}$$

特别地 $Cov(X,Y) = \rho \sigma_1 \sigma_2$

随机变量 X,Y 相互独立

- 集合 $\Leftrightarrow P\{X \in D_1, Y \in D_2\} = P\{X \in D_1\} \cdot P\{Y \in D_2\}$
联合 $\Leftrightarrow F(x,y) = F_X(x) F_Y(y) \Leftrightarrow P\{X \leq x, Y \leq y\} = P\{X \leq x\} \cdot P\{Y \leq y\} \Leftrightarrow P\{X \leq x, Y > y\} = P\{X \leq x\} \cdot P\{Y > y\}$
条件 $\Leftrightarrow f_{Y|X}(y|x) = f_Y(y) \Leftrightarrow P\{Y \in D_2 | X \in D_1\} = P\{Y \in D_2\} \Leftrightarrow P\{Y \in D_2 | X \in D_1\} = P\{Y \in D_2\}$
离散 $\Leftrightarrow \begin{cases} X,Y \text{ 离散 } \forall x_i, y_j \in R, \text{ 都有 } P\{X=x_i, Y=y_j\} = P\{X=x_i\} P\{Y=y_j\} \Leftrightarrow p_{ij} = p_{i.} p_{.j} \\ X,Y \text{ 连续 } \forall x,y \in R, \text{ 有 } \int_{-\infty}^x \int_{-\infty}^y f(u,v) du dv = \int_{-\infty}^x f_X(u) du \int_{-\infty}^y f_Y(v) dv \\ X \text{ 离散 } Y \text{ 连续 } F(x,y) = F_X(x) F_Y(y) \end{cases}$
多元正态 $\Leftrightarrow (X,Y)$ 为二维正态变量时 $\rho = 0$
范围 $\Leftrightarrow f(x,y)$ 为乘积形式 $f(x,y) = f_X(x) f_Y(y)$ 且 X,Y 范围为长方形

$$\Rightarrow Cov(X,Y) = 0 \Leftrightarrow \rho_{XY} = 0 \Leftrightarrow E(X,Y) = E(X)E(Y) \Leftrightarrow D(X,Y) = D(X) + D(Y)$$

多元随机变量函数的分布

- ① $Z = X+Y$ $P\{Z=z_k\} = \sum_{i,j} P\{X=x_i, Y=y_j, Z=z_k\} \xrightarrow{X,Y \text{ 独立}} \sum_{i,j} P\{X=x_i\} P\{Y=y_j, Z=z_k\}$
 $F_Z(z) = \iint_{x+y \leq z} f(x,y) dx dy = \int_{-\infty}^{+\infty} dx \int_{-\infty}^{z-x} f(x,y) dy \xrightarrow{u=x, v=y} \int_{-\infty}^{z-x} \int_{-\infty}^{+\infty} f(u,v) du dv$
 $f_Z(z) = \int_{-\infty}^{+\infty} f(x, z-x) dx \xrightarrow{X,Y \text{ 独立}} \int_{-\infty}^{+\infty} f_X(x) f_Y(z-x) dx$

再生性 (X,Y 独立) ① 泊松 $\frac{X}{\lambda} \sim P(\frac{\lambda}{\lambda})$

② 二项 $\frac{X}{n} \sim B(\frac{n}{n}, \frac{\lambda}{n})$

推广 $X_1, \dots, X_n$ 独立

$$F_{X_1}(x) = 1 - [1 - F_X(x)]^n$$

$$F_{X_1}(x) = [F_X(x)]^n$$

相互独立

$$M = \max\{X,Y\} \quad N = \min\{X,Y\}$$

- 相同用减
max $\leq t$ $F_M(t) = P\{\max\{X,Y\} \leq t\} = P\{X \leq t, Y \leq t\} = F_X(t) F_Y(t) \xrightarrow{X,Y \text{ 独立}} F_X(t) F_Y(t)$
max $> t$ $P\{\max\{X,Y\} > t\} = 1 - P\{X \leq t, Y \leq t\}$
min $\leq t$ $F_N(t) = P\{\min\{X,Y\} \leq t\} = F_X(t) + F_Y(t) - F_X(t) F_Y(t) = 1 - P\{X > t, Y > t\} \xrightarrow{X,Y \text{ 独立}} 1 - [1 - F_X(t)][1 - F_Y(t)]$
min $> t$ $P\{\min\{X,Y\} > t\} = P\{X > t, Y > t\}$

(更强的关联)

$$\text{不独立 } \text{独立} \Leftrightarrow \forall i, PC(X_i, Y_i) = P(X_i) P(Y_i)$$

$$\Leftrightarrow f(x,y) = f_X(x) f_Y(y) \Leftrightarrow F(x,y) = F_X(x) F_Y(y) \Leftrightarrow f_{X|Y}(x|y) = f_X(x)$$

$$\Leftrightarrow g(x) \text{ 与 } h(y) \text{ 相互独立} \Leftrightarrow E[g(x)h(y)] = E[g(x)]E[h(y)]$$

$$\text{相关 } \text{不相关} \Leftrightarrow Cov(X,Y) = 0 \Leftrightarrow \rho_{XY} = 0$$

(线性关联)

$$\Leftrightarrow E(X,Y) = E(X)E(Y) \Leftrightarrow D(X,Y) = D(X) + D(Y)$$

特殊情况: 二维正态分布 独立 $\Leftrightarrow$ 不相关 $\Leftrightarrow Cov(X,Y) = \rho \sigma_1 \sigma_2 = 0$

随机变量的数字特征

数学期望

- 定义 离散 $E(X) = \sum_{i=1}^{\infty} x_i p_i$ 绝对收敛
连续 $E(X) = \int_{-\infty}^{+\infty} x f(x) dx = \int_{-\infty}^{+\infty} x f(x,y) dy$
多维 $E(X,Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} xy f(x,y) dx dy$
性质 ① $E(c + \sum_{i=1}^n c_i X_i) = c + \sum_{i=1}^n c_i E(X_i)$
② X,Y 相互独立, 则 $E(XY) = E(X)E(Y) \Rightarrow X_1, \dots, X_n$ 相互独立, 则 $E(\prod_{i=1}^n X_i) = \prod_{i=1}^n E(X_i)$

方差

- ① 泊松分布 $E(X) = \lambda \quad \frac{X}{\lambda} \sim P(\frac{\lambda}{\lambda})$
② 二项分布 $E(X) = np$
③ 指数分布 $E(X) = \frac{1}{\lambda}$
④ 均匀分布 $E(X) = \frac{a+b}{2}$
⑤ 正态分布 $E(X) = \mu$ 标准正态分布 $E(X) = 0$
⑥ 超几何分布 $E(X) = n \frac{M}{N}$

函数

- ① 若 $\sum_{i=1}^{\infty} |g(x_i)| < +\infty$, 则 $E(g(X)) = \sum_{i=1}^{\infty} g(x_i) p_i$
若 $\int_{-\infty}^{+\infty} |g(x)| f(x) dx < +\infty$, 则 $E(g(X)) = \int_{-\infty}^{+\infty} g(x) f(x) dx$
② 若 $\sum_{i=1}^{\infty} h(x_i) p_i < +\infty$, 则 $E(g(X)) = \sum_{i=1}^{\infty} h(x_i) p_i$
若 $\int_{-\infty}^{+\infty} h(x) f(x) dx < +\infty$, 则 $E(g(X)) = \int_{-\infty}^{+\infty} h(x) f(x) dx$

方差

$$\text{定义 } Var(X) \text{ 或 } D(X) \text{ 或 } V(X) = E[(X-E(X))^2]$$

$$D(X) \text{ 或 } SD(X) = \sqrt{Var(X)}$$

性质

- ① $Var(X) = E(X^2) - (E(X))^2$
② $D(X) \leq E[(X-c)^2]$ 当且仅当 $E(X) = c$ 时成立
③ $D(X) = 0$ 当且仅当 $P\{X=c\} = 1$ 其中 $c = E(X)$
④ $X_1, \dots, X_n$ 两两独立, 则 $D(\sum X_i) = \sum D(X_i)$
⑤ $X_1, \dots, X_n$ 两两独立, 则 $D(a + \sum c_i X_i) = \sum c_i^2 D(X_i)$

协方差

$$\text{定义 } Cov(X,Y) = E[(X-E(X))(Y-E(Y))] = E(XY) - E(X)E(Y)$$

- ① 离散 $P\{X=x_i, Y=y_j\} = p_{ij} \quad Cov(X,Y) = \sum_{i,j} (x_i - E(X))(y_j - E(Y)) p_{ij}$
② 连续 $f(x,y) \quad Cov(X,Y) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} (x-E(X))(y-E(Y)) f(x,y) dx dy$
③ 泊松分布 $E(X) = \lambda + \lambda \quad D(X) = \lambda$
④ 二项分布 $X = \sum_{i=1}^n \varepsilon_i \sim B(n, p) \quad P(\varepsilon_i) = p(1-p) \quad D(X) = np(1-p)$
⑤ 指数分布 $E(X) = \frac{1}{\lambda} \quad D(X) = \frac{1}{\lambda^2}$
⑥ 均匀分布 $E(X) = \frac{a+b}{2} \quad D(X) = \frac{(b-a)^2}{12}$
⑦ 正态分布 $Z = \frac{X-\mu}{\sigma} \sim N(0,1) \quad D(X) = \sigma^2$
⑧ 标准正态分布 $E(X) = 1 \quad D(X) = 1$

性质

$$D(\sum_{i=1}^n X_i) = \sum_{i,j=1}^n D(X_i, X_j) \geq \sum_{i=1}^n D(X_i)$$

相关

- ① $Cov(X,Y) = Cov(Y,X)$
② $Cov(X,X) = D(X)$
③ $Cov(aX, bY) = ab Cov(X,Y)$
④ 若 $Cov(X_i, Y_i) (i=1,2,3) \neq 0$, 则 $Cov(X_1+X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$
⑤ 若 X,Y 相互独立, 则 $Cov(X,Y) = 0$ 反之不成立
⑥ 若 $D(X)D(Y) \neq 0$ 时, 有 $(Cov(X,Y))^2 \leq D(X)D(Y)$ 成立当且仅当 $P\{Y=c+GX\} = 1$

(线性)相关系数

$$\text{定义 } \rho_{XY} = \frac{Cov(X,Y)}{\sqrt{D(X)D(Y)}}$$

非线性相关

$$\rho_{XY} = 0 \Leftrightarrow Cov(X,Y) = 0 \Leftrightarrow E(X,Y) = E(X)E(Y) \Leftrightarrow D(X,Y) = D(X) + D(Y)$$

性质

- ① 若 X,Y 相互独立, 则 $\rho_{XY} = 0$ 反之不成立
② $|\rho_{XY}| \leq 1$ 成立当且仅当 $P\{Y=c+GX\} = 1$
③ 两相互独立随机变量, 若方差存在, 则一定不相关
若不相干, 则未必独立
若相关, 则一定不独立

矩

$$k \text{ 阶原点矩 } \mu_k = E(X^k) = \begin{cases} \sum_{i=1}^{\infty} x_i^k P(X=x_i) & \text{离散} \\ \int_{-\infty}^{+\infty} x^k f(x) dx & \text{连续} \end{cases}$$

$$k \text{ 阶中心矩 } \mu_k = E[(X-E(X))^k]$$

$$k+1 \text{ 阶混合原点矩 } E(X^k Y)$$

$$k+1 \text{ 阶混合中心矩 } E[(X-E(X))^k (Y-E(Y))]$$

分位数

$$\forall 0 < \alpha < 1 \quad P\{X > x_\alpha\} = 1 - F(x_\alpha) = \int_{x_\alpha}^{+\infty} f(x) dx = \alpha$$

- $\begin{cases} \alpha = \frac{1}{2} & \text{中位数} \\ \alpha = \frac{1}{4} & \text{上四分位数} \\ \alpha = \frac{3}{4} & \text{上七分位数} \end{cases}$

x_α 为 X 的 α 上(侧)分位数

大数定理

现象描述

依概率收敛 $Y_n \xrightarrow{P} c \ (n \rightarrow \infty) \Leftrightarrow \forall \varepsilon > 0, \lim_{n \rightarrow \infty} P\{|Y_n - c| \geq \varepsilon\} = 0 \Leftrightarrow \lim_{n \rightarrow \infty} P\{|Y_n - c| < \varepsilon\} = 1$

性质: $X_n \xrightarrow{P} a \quad Y_n \xrightarrow{P} b \quad n \rightarrow \infty$ 若 φ 函数 $g(x,y)$ 在 (a,b) 连续, 则 $g(X_n, Y_n) \xrightarrow{P} g(a,b) \quad n \rightarrow \infty$

工具

马尔可夫不等式 若 Y 的 k 阶原点矩存在 ($k \geq 1$), 则 $\forall \varepsilon > 0$, 有 $P\{|Y| \geq \varepsilon\} \leq \frac{E(|Y|^k)}{\varepsilon^k} \Leftrightarrow P\{|Y| < \varepsilon\} \geq 1 - \frac{E(|Y|^k)}{\varepsilon^k}$
 $\Rightarrow k=2$ 切比雪夫不等式 若 $E(X) = \mu, D(X) = \sigma^2$ 存在, 则 $\forall \varepsilon > 0$, 有 $P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2} \Leftrightarrow P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$

无论分布类型, 只要知道 $E(X)$ 和 $D(X)$, 就可以估计落入 $(\mu - \varepsilon, \mu + \varepsilon)$ 的概率

结论/定理

大数定律 $\frac{1}{n} \sum_{i=1}^n X_i - c_n \xrightarrow{P} 0 \ (n \rightarrow \infty)$

$\exists \{c_n, n \geq 1\}$ 使 $\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P\{|\frac{1}{n} \sum_{i=1}^n X_i - c_n| \geq \varepsilon\} = 0 \Leftrightarrow \lim_{n \rightarrow \infty} P\{|\frac{1}{n} \sum_{i=1}^n X_i - c_n| < \varepsilon\} = 1$

伯努利大数定律 $PA_i = p, \forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|\frac{n_A}{n} - p| \geq \varepsilon\} = 0$

用频率的极限来定义概率

辛钦大数定律 $\{X_i, i \geq 1\}$ 独立同分布且 $E(X)$ 存在, $\forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|\frac{1}{n} \sum_{i=1}^n X_i - \mu| \geq \varepsilon\} = 0$

$\Rightarrow$ 推论: $\{X_i, i \geq 1\}$ 独立同分布 $E(|h(X)|) < \infty, \forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|\frac{1}{n} \sum_{i=1}^n h(X_i) - \mu| \geq \varepsilon\} = 0$

什么时候用什么?

- ① 说明可近似: 大数定律
- ② 定义/描述稳定性: 依概率收敛
- ③ 证明稳定性: 不等式
- ④ 未知分布, 估算偏离程度: 不等式

推广后的大数定律可用于
很多用样本估计总体的场合
而不仅是 $\frac{1}{n} \sum X_i \xrightarrow{P} E(X)$
比如 $S_n^2 = \frac{1}{n} \sum X_i^2 - \bar{X}^2 \xrightarrow{P} E(X^2) - \bar{X}^2 = \sigma^2$
同理 $S^2 \xrightarrow{P} \sigma^2$
做题时统称 "由大数定律"

中心极限定理

用正态分布近似

林德伯格-莱维中心极限定理: 独立同分布

$\{X_i, i \geq 1\}$ 独立同分布且 $E(X_i) = \mu, D(X_i) = \sigma^2$ 存在, 则 $\forall x \in R, \lim_{n \rightarrow \infty} P\left\{\frac{\sum_{i=1}^n X_i - E(\sum_{i=1}^n X_i)}{\sqrt{\text{Var}(\sum_{i=1}^n X_i)}} \leq x\right\} = \Phi(x)$

$\Rightarrow$ 当 n 充分大时 $\frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} = \frac{\sum_{i=1}^n X_i - n\mu}{\sigma\sqrt{n}} \xrightarrow{\text{近似}} N(0,1)$

$\Rightarrow$ 推论: 棣莫弗-拉普拉斯中心极限定理 二项分布

$PA_i = p$, 则 $\forall x \in R$, 有 $\lim_{n \rightarrow \infty} P\left\{\frac{n_A - np}{\sqrt{np(1-p)}} \leq x\right\} = \Phi(x)$

$\Rightarrow$ 当 n 充分大时 $B(n,p) \xrightarrow{\text{近似}} N(np, np(1-p))$

3. 中心极限定理到底在说什么?

中心极限定理 (CLT) 的主角是样本均值 $\bar{X}$ (或前样本之和 $\sum_{i=1}^n X_i$)。

它的本质含义是:

如果你从总体中随机抽取 n 个样本, 算出它们的平均值, 然后你重复这个过程很多多次, 得到一大堆“平均值”。

这些“平均值”构成的分布, 才是正态分布。

形象化对比: 掷骰子实验

假设你掷一颗六面骰子, 点数 X 的分布是均匀分布 (1-6 概率一样, 完全不像钟形)。

• 模拟抽数据: 你掷 1000 次, 你会得到大约 166 个 1, 166 个 2... 图形是平的。

• 看大数定律: 这 1000 次的平均值, 会非常接近 3.5。

• 看中心极限定理:

• 你每次掷 30 颗骰子, 算出这 30 颗的平均分。

• 你记录下这个平均分, 然后重复掷“30颗”这个动作 1000 次。

• 你会发现, 虽然单颗骰子是平的, 但这 1000 个“平均分”画出来的图形, 是一个完美的钟形 (正态分布)。

总结: 中心极限定理的“三不”原则

1. 不要说原始总体服从正态分布。

2. 不要说你抽取的这组样本数据服从正态分布。

3. 不要说你当你把样本量 n 取得足够大时 (通常 $n \geq 30$), “平均值”这个统计量的随机波动规律趋向于正态分布。

为什么这个定理这么伟大?

因为它告诉统计学家: 我不需要知道总体的背景到底有多怪异, 只要我拿到足够多的样本, 我就可以用正态分布的公式去推算平均值的误差和置信区间。这就是统计学中有乙 检验, 误差估计的数字底气。

常见根无率分布表

分布	参数	概率分布律或密度函数	数学期望	方差
(0-1) 分布	$0 < p < 1$	$P\{X=k\} = p^k(1-p)^{1-k}, k=0,1$	p	$p(1-p)$
二项分布	$n \geq 1$ $0 < p < 1$	$P\{X=k\} = C_n^k p^k (1-p)^{n-k}, k=0,1,\dots,n$	np	$np(1-p)$
几何分布	$0 < p < 1$	$P\{X=k\} = (1-p)^{k-1} p, k=1,2,\dots$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
负二项分布 (帕斯卡分布)	$r \geq 1$ $0 < p < 1$	$P\{X=k\} = C_{k-1}^{r-1} p^r (1-p)^{k-r}, k=r,r+1,\dots$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
超几何分布	N, M, n $(M \leq N)$ $(n \leq N)$	$P\{X=k\} = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n},$ k 为整数, $\max\{0, n-N+M\} \leq k \leq \min\{n, M\}$	$\frac{nM}{N}$	$\frac{nM}{N} \left(1 - \frac{M}{N}\right) \frac{N-n}{N-1}$
泊松分布	$\lambda > 0$	$P\{X=k\} = \frac{\lambda^k e^{-\lambda}}{k!}, k=0,1,2,\dots$	λ	λ
均匀分布	$a < b$	$f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其他} \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态分布	$\mu,$ $\sigma > 0$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2
指数分布 (负指数分布)	$\lambda > 0$	$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & \text{其他} \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$
Γ 分布	$\alpha > 0,$ $\beta > 0$	$f(x) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0 \\ 0, & \text{其他} \end{cases}$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$
χ^2 分布	$n \geq 1$	$f(x) = \begin{cases} \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-x/2}, & x > 0 \\ 0, & \text{其他} \end{cases}$	n	$2n$
威布尔分布	$\eta > 0,$ $\beta > 0$	$f(x) = \begin{cases} \frac{\beta}{\eta} \left(\frac{x}{\eta}\right)^{\beta-1} e^{-\left(\frac{x}{\eta}\right)^\beta}, & x > 0 \\ 0, & \text{其他} \end{cases}$	$\eta \Gamma\left(\frac{1}{\beta} + 1\right)$	$\eta^2 \left[\Gamma\left(\frac{2}{\beta} + 1\right) - \left(\Gamma\left(\frac{1}{\beta} + 1\right)\right)^2\right]$
瑞利分布	$\sigma > 0$	$f(x) = \begin{cases} \frac{x}{\sigma^2} e^{-x^2/(2\sigma^2)}, & x > 0 \\ 0, & \text{其他} \end{cases}$	$\sqrt{\frac{\pi}{2}} \sigma$	$\frac{4-\pi}{2} \sigma^2$
β 分布	$\alpha > 0,$ $\beta > 0$	$f(x) = \begin{cases} \frac{\Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)} x^{\alpha-1} (1-x)^{\beta-1}, & 0 < x < 1 \\ 0, & \text{其他} \end{cases}$	$\frac{\alpha}{\alpha+\beta}$	$\frac{\alpha\beta}{(\alpha+\beta)^2(\alpha+\beta+1)}$
对数正态分布	$\mu,$ $\sigma > 0$	$f(x) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma x} e^{-(\ln x - \mu)^2/(2\sigma^2)}, & x > 0 \\ 0, & \text{其他} \end{cases}$	$e^{\mu + \frac{\sigma^2}{2}}$	$e^{2\mu + \sigma^2} (e^{\sigma^2} - 1)$
柯西分布	$a,$ $\lambda > 0$	$f(x) = \frac{1}{\pi} \frac{\lambda}{\lambda^2 + (x-a)^2}$	不存在	不存在
t 分布	$n \geq 1$	$f(x) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{x^2}{n}\right)^{-\frac{n+1}{2}}$	$0, n > 1$	$\frac{n}{n-2}, n > 2$
F 分布	n_1, n_2	$f(x) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2} x\right)^{-\frac{n_1+n_2}{2}}, & x > 0 \\ 0, & \text{其他} \end{cases}$	$\frac{n_2}{n_2-2}, n_2 > 2$	$\frac{2n_2^2(n_1+n_2-2)}{n_1(n_2-2)^2(n_2-4)}, n_2 > 4$

统计

统计量与抽样分布

参数估计 → 用样本估计总体

1. 样本 & 统计量

简单随机样本: 独立同分布

样本联合分布函数 $F_n(x_1, x_2, \dots, x_n) = \prod_{i=1}^n F(x_i)$
样本联合密度函数 $f_n(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f(x_i)$

统计量 $g(X_1, X_2, \dots, X_n)$ 样本的函数

① 样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \Rightarrow E(\bar{X}) = EX \quad D(\bar{X}) = \frac{1}{n} DX$
② 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} (\sum_{i=1}^n X_i^2 - n\bar{X}^2)$
③ 样本协方差 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$
④ 样本k阶中心矩 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

本质区别
矩法 大数定律 (让样本矩=总体矩)
极大似然 使观测结果出现的概率最大化

1. 点估计

构造一个适当统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 为 θ 的 (点) 估计量
 X_n 样本, θ 样本值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 为 θ 的估计值
当 $n \rightarrow \infty$ 时的矩估计量为参数的相合估计

① 矩法 当 $n \rightarrow \infty$ 时 样本矩 $\xrightarrow{P}$ 总体矩 原点矩: $A_k \xrightarrow{P} \mu_k$ 中心矩: $B_k \xrightarrow{P} \sigma_k$

方法: ① 用待估参数 $\theta_1, \dots, \theta_m$ 表示 $\mu_1, \dots, \mu_m$
② 解方程, 用 $\mu_1, \dots, \mu_m$ 表示 $\theta_1, \dots, \theta_m$
③ 用 A_i 代替表达式中 μ_i

典例: ① 指数分布 $\mu_1 = EX = \frac{1}{\lambda} \quad \lambda = \frac{1}{\mu_1} \quad \lambda = \frac{1}{\bar{X}} = \frac{n}{\sum X_i}$

② 均匀分布 $\begin{cases} \mu_1 = EX = \frac{a+b}{2} \\ \mu_2 = DX = \frac{(b-a)^2}{12} \end{cases} \Rightarrow \begin{cases} a = \mu_1 - \sqrt{3}\mu_2 \\ b = \mu_1 + \sqrt{3}\mu_2 \end{cases} \Rightarrow \begin{cases} \hat{a} = \bar{X} - \sqrt{3}S \\ \hat{b} = \bar{X} + \sqrt{3}S \end{cases}$

③ 正态分布 $\begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = A_2 - \bar{X}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 = B_2 \end{cases}$

④ 任意分布 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = A_2 - \bar{X}^2$

$\begin{cases} EX = \mu \\ E(X^2) = \sigma^2 + \mu^2 \end{cases} \Rightarrow \begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = A_2 - \bar{X}^2 = B_2 \end{cases}$ 矩估计不涉及分布

2. 三个抽样分布

积累 ① χ^2 分布 $Y \sim \chi^2(n)$ 偏离中心的总体程度

正数 $X_1, \dots, X_n$ 独立同分布 $N(0, 1)$, 则 $Y = X_1^2 + X_2^2 + \dots + X_n^2$ 服从自由度为 n 的 χ^2 分布

① $E(Y) = n \quad D(Y) = 2n$
② $Y_1, \dots, Y_m$ 相互独立, 则 $\sum_{i=1}^m Y_i \sim \chi^2(\sum_{i=1}^m n_i)$
③ $P\{X > \chi^2_{\alpha}(n)\} = \int_{\chi^2_{\alpha}(n)}^{\infty} f_X(x) dx = \alpha$

修正 ② t 分布 $t \sim t(n)$

对称 像正态 $X \sim N(0, 1) \quad Y \sim \chi^2(n)$ 且 X, Y 相互独立, 则 $t = \frac{X}{\sqrt{Y/n}}$ 服从自由度为 n 的 t 分布
用样本 S 估计总体 σ

① $f_X(x)$ 偶函数
② $\int_{-\infty}^{\infty} f_X(x) dx = \frac{1}{\sqrt{n\pi}} e^{-x^2/2}$
③ $t_{2n}(m) = -t_{2n}(m)$

比较 ③ F 分布 $F \sim F(n_1, n_2)$ 比较两者波动大小

倒数 $U \sim \chi^2(n_1) \quad V \sim \chi^2(n_2)$ 且 U, V 相互独立, 则 $F = \frac{U/n_1}{V/n_2}$ 服从第一自由度为 n_1 , 第二自由度为 n_2 的 F 分布

① 若 $F \sim F(n_1, n_2)$ 则 $\frac{1}{F} \sim F(n_2, n_1)$
② 若 $X \sim t(n)$ 则 $X^2 \sim F(1, n)$
③ $P\{F > F_{\alpha}(n_1, n_2)\} = \int_{F_{\alpha}(n_1, n_2)}^{\infty} f_F(x) dx = \alpha \quad F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$

观察到这组样本
的联合概率密度函数

② 极大似然法 - MLE 具有不变性

似然函数 $L(\theta) = L(\theta; X_1, X_2, \dots, X_n) = \begin{cases} \prod_{i=1}^n p(X_i; \theta) & \text{离散} \\ \prod_{i=1}^n f(X_i; \theta) & \text{连续} \end{cases}$

典例: ① 伯努利分布 $\lambda = \frac{1}{n} \sum X_i = \bar{X}$

② 正态分布 $\begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 \end{cases}$

方法: ① 似然方程有解

$L(\theta) = \prod_{i=1}^n p(X_i; \theta)$

$\frac{dL(\theta)}{d\theta} \Big|_{\theta=\hat{\theta}} = 0$

$L(\theta) = g_n L(\theta) \quad \frac{dL(\theta)}{d\theta} = 0$

② 无解

$L(\theta)$ 关于 θ 单调

$\theta \uparrow \uparrow \quad \theta \leq X_1, \dots, X_n \Rightarrow \hat{\theta} = \min_{1 \leq i \leq n} X_i = X_{(1)}$

$\theta \downarrow \downarrow \quad X_1, \dots, X_n \leq \theta \Rightarrow \hat{\theta} = \max_{1 \leq i \leq n} X_i = X_{(n)}$

似然方程 $\frac{dL(\theta)}{d\theta} \Big|_{\theta=\hat{\theta}} = 0$

对数似然函数 $l(\theta) = \ln L(\theta)$

对数似然方程 $\frac{dl(\theta)}{d\theta} \Big|_{\theta=\hat{\theta}} = 0$

极大似然估计值 $\hat{\theta}(X_1, X_2, \dots, X_n)$

极大似然估计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$

③ 双参数

①②混用 (先①后②)

求偏导

3. 正态总体下的抽样分布

定理: $X_1, \dots, X_n$ 为 $N(\mu, \sigma^2)$ 的简单随机样本

① 样本均值 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

② $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

③ $\bar{X}$ 与 S^2 相互独立

④ $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$

定理: $X_1, \dots, X_{n_1}$ 和 $Y_1, \dots, Y_{n_2}$ 分别为来自 $N(\mu_1, \sigma^2)$ 和 $N(\mu_2, \sigma^2)$ 的两相互独立的简单随机样本

① $\frac{S_1^2/\sigma^2}{S_2^2/\sigma^2} \sim F(n_1-1, n_2-1)$

② 当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时 $\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$ 其中 $S_w^2 = \frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1 + n_2 - 2}$ $S_w = \sqrt{S_w^2}$
合样本方差

误区:

① 在抽取样本前置信区间是随机的, 但在样本确定并算出区间端点 $L(x_1, x_n)$ 后, 区间就固定死了

② 概率 + 置信度

置信度 (水平) 95%: 这种构造区间的方法是可靠的, 如果重复 100 次实验 有 95 个实验区间套住了真正的参数

而每次套圈要么中 (概率为 1) 要么不中 (概率为 0)

2. 估计量的评价准则

① 无偏性 $\begin{cases} E(\hat{\theta}) = \theta & \text{无偏} \\ E(\hat{\theta}) \neq \theta & \begin{cases} E(\hat{\theta}) - \theta \text{ 为 } \theta \text{ 的偏差} \\ \lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta \text{ 渐近无偏} \end{cases} \end{cases}$

② 有效性 $\hat{\theta}_1$ 与 $\hat{\theta}_2$ 均无偏 $\forall \theta \in \Theta \quad \text{Var}_{\theta}(\hat{\theta}_1) \leq \text{Var}_{\theta}(\hat{\theta}_2)$ 且至少一个 θ 为 $\neq$

③ 均方误差 $Mse(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = D(\hat{\theta}) + (E(\hat{\theta}) - \theta)^2$ 无偏 $D(\hat{\theta})$
 $\forall \theta \in \Theta \quad Mse(\hat{\theta}_1) \leq Mse(\hat{\theta}_2)$ 且至少一个 θ 为 $\neq$

④ 相合性 $\forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} P\{|\hat{\theta}_n - \theta| \leq \varepsilon\} = 1 \quad \hat{\theta}_n \xrightarrow{P} \theta \quad n \rightarrow \infty$ 矩法一般都相合 似然不一定

3. 区间估计 → 精度 (区间宽度) + 可靠性 (置信水平)

① $\hat{\theta}_L$ 和 $\hat{\theta}_U$ 对给定 $\alpha(0, 1)$ 和 $\forall \theta \in \Theta$ 有 $P\{\hat{\theta}_L < \theta < \hat{\theta}_U\} \geq 1 - \alpha$
则 随机区间 $(\hat{\theta}_L, \hat{\theta}_U)$ 为 θ 的置信水平为 $1 - \alpha$ 的置信区间 - 双侧置信上下限

$E(\hat{\theta}_U - \hat{\theta}_L)$ 为 $(\hat{\theta}_L, \hat{\theta}_U)$ 的精确度 $\pm E(\hat{\theta}_U - \hat{\theta}_L)$ 为 $(\hat{\theta}_L, \hat{\theta}_U)$ 的误差限

② 奈曼原则: 在保证置信水平达到一定的前提下, 尽可能提高精确度 → 区间怎取 < 连续 = 成立 离散 = 尽可能接近

当样本容量 n 给定时, 置信水平和精确度相互制约

若要同时提高置信水平和精确度, 只有增大样本容量 n

③ $P\{\hat{\theta}_L < \theta\} \geq 1 - \alpha$ 单侧置信下限 $P\{\theta < \hat{\theta}_U\} \geq 1 - \alpha$ 单侧置信上限

④ 引理: 若 $P\{\hat{\theta}_L < \theta\} \geq 1 - \alpha_1 \quad P\{\theta < \hat{\theta}_U\} \geq 1 - \alpha_2$ 则 $P\{\hat{\theta}_L < \theta < \hat{\theta}_U\} \geq 1 - \alpha_1 - \alpha_2, (\hat{\theta}_L, \hat{\theta}_U)$ 为 θ 的置信水平为 $1 - \alpha_1 - \alpha_2$ 的置信区间

4. 正态总体参数的区间估计

	待估参数	其他参数	枢轴量的分布	置信区间	单侧置信限
单个正态总体	μ	σ^2 已知	$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$	$\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right)$ <i>S误差限</i>	$\hat{\mu}_U = \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha}$ $\hat{\mu}_L = \bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha}$
	μ	σ^2 未知	$t = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$	$\left(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right)$	$\hat{\mu}_U = \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha}(n-1)$ $\hat{\mu}_L = \bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1)$
	σ^2	μ 未知	$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	$\left(\frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} \right)$	$\hat{\sigma}_U^2 = \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)}$ $\hat{\sigma}_L^2 = \frac{(n-1)S^2}{\chi_{\alpha}^2(n-1)}$
两个正态总体	$\mu_1 - \mu_2$	σ_1^2 和 σ_2^2 已知	$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0, 1)$	$\left(\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right)$	$(\mu_1 - \mu_2)_U = \bar{X} - \bar{Y} + z_{\alpha} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$ $(\mu_1 - \mu_2)_L = \bar{X} - \bar{Y} - z_{\alpha} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$
	$\mu_1 - \mu_2$	$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知	$t = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$ 其中 $S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$	$\left(\bar{X} - \bar{Y} \pm t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right)$	$(\mu_1 - \mu_2)_U = \bar{X} - \bar{Y} + t_{\alpha}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$ $(\mu_1 - \mu_2)_L = \bar{X} - \bar{Y} - t_{\alpha}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$
	$\mu_1 - \mu_2$	$\sigma_1^2 \neq \sigma_2^2$ 未知	$t = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$ $\begin{cases} \sim N(0, 1), & n_1, n_2 > 50, \\ \sim t(k), & k = \min(n_1 - 1, n_2 - 1) \end{cases}$	$\left(\bar{X} - \bar{Y} \pm q_{\alpha/2} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}} \right)$ 其中 $q_p = \begin{cases} z_p, & \text{用 } t \sim N(0, 1) \text{ 近似,} \\ t_p(k), & \text{用 } t \sim t(k) \text{ 近似} \end{cases}$	$(\mu_1 - \mu_2)_U = \bar{X} - \bar{Y} + q_{\alpha} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$ $(\mu_1 - \mu_2)_L = \bar{X} - \bar{Y} - q_{\alpha} \sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}$
	$\frac{\sigma_1^2}{\sigma_2^2}$	μ_1, μ_2 未知	$F = \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$	$\left(\frac{S_1^2/S_2^2}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1 - 1, n_2 - 1)} \right)$	$\left(\frac{\sigma_1^2}{\sigma_2^2} \right)_U = \frac{S_1^2/S_2^2}{F_{1-\alpha}(n_1 - 1, n_2 - 1)}$ $\left(\frac{\sigma_1^2}{\sigma_2^2} \right)_L = \frac{S_1^2/S_2^2}{F_{\alpha}(n_1 - 1, n_2 - 1)}$

成对数据
 $D_i = X_i - Y_i$
 $\bar{D} = \bar{X} - \bar{Y}$
 $S_D^2 = \frac{1}{n-1} \sum (D_i - \bar{D})^2$

假设检验

H_0 拒绝域 / P值 $\Rightarrow$ 不等号方向相同
★ 拒绝域和原假设的不等式带 "="

μ 已知: Z 检验
 σ 未知: t 检验
单: χ^2 检验
双: F 检验

1. 基本思想

① 原/零假设 H_0 - 备择/对立假设 H_1


$H_0: \theta \geq 0, H_1: \theta < 0$ 左侧检验 $\rightarrow H_0: \theta = 0, H_1: \theta < 0$
 $H_0: \theta \leq 0, H_1: \theta > 0$ 右侧检验 $\rightarrow H_0: \theta = 0, H_1: \theta > 0$
 $H_0: \theta = 0, H_1: \theta \neq 0$ 双侧检验

② 检验统计量 $\in$ 拒绝域 $W \Rightarrow$ 拒绝原假设 H_0
接受域 $\bar{W}$

③ $\alpha = P(\text{第 I 类错误}) = P(\text{拒绝 } H_0 | H_0 \text{ 是真实的}) = P(\bar{X} > c | \mu = 0) = 1 - \Phi\left(\frac{c}{\sigma/\sqrt{n}}\right)$
 $\beta = P(\text{第 II 类错误}) = P(\text{接受 } H_0 | H_0 \text{ 是错误的}) = P(\bar{X} < c | \mu = \theta) = \Phi\left(\frac{c - \theta}{\sigma/\sqrt{n}}\right)$

奈曼-皮尔逊原则

鉴于上述情况, 奈曼和皮尔逊提出: 首先控制犯第 I 类错误的概率, 即选定一个常数 $\alpha \in (0, 1)$, 要求犯第 I 类错误的概率不超过 α ; 然后在满足这个约束条件的检验中, 再寻找检验, 使得犯第 II 类错误的概率尽可能小。这就是假设检验理论中的奈曼-皮尔逊原则。其中的常数 α 称为显著性水平。



④ P值: H_0 成立时, 检验统计量 $\geq$ 观测值的概率

若 $P \leq \alpha$ 则拒绝原假设, 称检验结果在 α 下是统计显著的

2. 正态总体参数的假设检验

	原假设 H_0	检验统计量	备择假设 H_1	拒绝域	检验统计量的取值	P-值
1	$\mu \leq \mu_0$ $\mu \geq \mu_0$ $\mu = \mu_0$ (σ^2 已知)	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$\mu > \mu_0$ $\mu < \mu_0$ $\mu \neq \mu_0$	$Z \geq z_{\alpha}$ $Z \leq -z_{\alpha}$ $ Z \geq z_{\alpha/2}$	$z_0 = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$	$1 - \Phi(z_0)$ $\Phi(z_0)$ $2(1 - \Phi(z_0))$
2	$\mu \leq \mu_0$ $\mu \geq \mu_0$ $\mu = \mu_0$ (σ^2 未知)	$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$\mu > \mu_0$ $\mu < \mu_0$ $\mu \neq \mu_0$	$T \geq t_{\alpha}(n-1)$ $T \leq -t_{\alpha}(n-1)$ $ T \geq t_{\alpha/2}(n-1)$	$t_0 = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$	$P\{t(n-1) \geq t_0\}$ $P\{t(n-1) \leq t_0\}$ $2P\{t(n-1) \geq t_0 \}$
3	$\mu_1 - \mu_2 \leq \delta$ $\mu_1 - \mu_2 \geq \delta$ $\mu_1 - \mu_2 = \delta$ (σ_1^2, σ_2^2 已知)	$Z = \frac{\bar{X} - \bar{Y} - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$\mu_1 - \mu_2 > \delta$ $\mu_1 - \mu_2 < \delta$ $\mu_1 - \mu_2 \neq \delta$	$Z \geq z_{\alpha}$ $Z \leq -z_{\alpha}$ $ Z \geq z_{\alpha/2}$	$z_0 = \frac{\bar{x} - \bar{y} - \delta}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}}$	$1 - \Phi(z_0)$ $\Phi(z_0)$ $2(1 - \Phi(z_0))$
4	$\mu_1 - \mu_2 \leq \delta$ $\mu_1 - \mu_2 \geq \delta$ $\mu_1 - \mu_2 = \delta$ ($\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知)	$T = \frac{\bar{X} - \bar{Y} - \delta}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$ $S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$	$\mu_1 - \mu_2 > \delta$ $\mu_1 - \mu_2 < \delta$ $\mu_1 - \mu_2 \neq \delta$	$T \geq t_{\alpha}(n_1 + n_2 - 2)$ $T \leq -t_{\alpha}(n_1 + n_2 - 2)$ $ T \geq t_{\alpha/2}(n_1 + n_2 - 2)$	$t_0 = \frac{\bar{x} - \bar{y} - \delta}{s_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}$	$P\{t(n_1 + n_2 - 2) \geq t_0\}$ $P\{t(n_1 + n_2 - 2) \leq t_0\}$ $2P\{t(n_1 + n_2 - 2) \geq t_0 \}$ 小写
5	$\mu_1 - \mu_2 \leq \delta$ $\mu_1 - \mu_2 > \delta$ $\mu_1 - \mu_2 = \delta$ ($\sigma_1^2 \neq \sigma_2^2$ 未知, 大样本情形)	$T = \frac{\bar{X} - \bar{Y} - \delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$	$\mu_1 - \mu_2 > \delta$ $\mu_1 - \mu_2 < \delta$ $\mu_1 - \mu_2 \neq \delta$	$T \geq z_{\alpha}$ $T \leq -z_{\alpha}$ $ T \geq z_{\alpha/2}$	$t_0 = \frac{\bar{x} - \bar{y} - \delta}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$	$1 - \Phi(t_0)$ $\Phi(t_0)$ $2(1 - \Phi(t_0))$
6	$\mu_1 - \mu_2 \leq \delta$ $\mu_1 - \mu_2 > \delta$ $\mu_1 - \mu_2 = \delta$ ($\sigma_1^2 \neq \sigma_2^2$ 未知)	$T = \frac{\bar{X} - \bar{Y} - \delta}{\sqrt{\frac{S_1^2}{n_1} + \frac{S_2^2}{n_2}}}$	$\mu_1 - \mu_2 > \delta$ $\mu_1 - \mu_2 < \delta$ $\mu_1 - \mu_2 \neq \delta$	$T \geq t_{\alpha}(k)$ $T \leq -t_{\alpha}(k)$ $ T \geq t_{\alpha/2}(k)$ $k = \min(n_1 - 1, n_2 - 1)$ 或采用公式 (8.3.6)	$t_0 = \frac{\bar{x} - \bar{y} - \delta}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$	$P\{t(k) \geq t_0\}$ $P\{t(k) \leq t_0\}$ $2P\{t(k) \geq t_0 \}$
7	$\sigma^2 \leq \sigma_0^2$ $\sigma^2 > \sigma_0^2$ $\sigma^2 = \sigma_0^2$ (μ 未知)	$\chi^2 = \frac{(n-1)S^2}{\sigma_0^2}$	$\sigma^2 > \sigma_0^2$ $\sigma^2 < \sigma_0^2$ $\sigma^2 \neq \sigma_0^2$	$\chi^2 \geq \chi_{1-\alpha}^2(n-1)$ $\chi^2 \leq \chi_{\alpha}^2(n-1)$ $\chi^2 \geq \chi_{\alpha/2}^2(n-1)$ 或 $\chi^2 \leq \chi_{1-\alpha/2}^2(n-1)$	$\chi_0^2 = \frac{(n-1)s^2}{\sigma_0^2}$	$P\{\chi^2(n-1) \geq \chi_0^2\}$ $P\{\chi^2(n-1) \leq \chi_0^2\}$ $2 \min\{p_0, 1 - p_0\}$ (其中 $p_0 = P\{\chi^2(n-1) \leq \chi_0^2\}$)
8	$\sigma_1^2 \leq \sigma_2^2$ $\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 = \sigma_2^2$ (μ_1, μ_2 未知)	$F = \frac{S_1^2}{S_2^2}$	$\sigma_1^2 > \sigma_2^2$ $\sigma_1^2 < \sigma_2^2$ $\sigma_1^2 \neq \sigma_2^2$	$F \geq F_{\alpha}(n_1 - 1, n_2 - 1)$ $F \leq F_{1-\alpha}(n_1 - 1, n_2 - 1)$ $F \geq F_{\alpha/2}(n_1 - 1, n_2 - 1)$ 或 $F \leq F_{1-\alpha/2}(n_1 - 1, n_2 - 1)$	$f_0 = \frac{s_1^2}{s_2^2}$	$P\{F(n_1 - 1, n_2 - 1) \geq f_0\}$ $P\{F(n_1 - 1, n_2 - 1) \leq f_0\}$ $2 \min\{p_0, 1 - p_0\}$ (其中 $p_0 = P\{F(n_1 - 1, n_2 - 1) \leq f_0\}$)
9	$\mu_D \leq \delta$ $\mu_D > \delta$ $\mu_D = \delta$ (成对数据)	$T = \frac{\bar{D} - \delta}{S_D/\sqrt{n}}$	$\mu_D > \delta$ $\mu_D < \delta$ $\mu_D \neq \delta$	$T \geq t_{\alpha}(n-1)$ $T \leq -t_{\alpha}(n-1)$ $ T \geq t_{\alpha/2}(n-1)$	$t_0 = \frac{\bar{d} - \delta}{s_d/\sqrt{n}}$	$P\{t(n-1) \geq t_0\}$ $P\{t(n-1) \leq t_0\}$ $2P\{t(n-1) \geq t_0 \}$

正态分布对称, 而 F 不对称

F 不对称

3. 形象对比		
特性	区间估计 (Estimation)	假设检验 (Testing)
思维逻辑	正向: 由样本推测总体范围	逆向: 由样本去挑战预设前提
关注点	误差有多大? (精确度)	数据够不够打脸? (显著性)
角色比喻	天气预报员: 预测明天气温在 20-25 度之间	打假斗士: 你说气温是 15 度, 但我测出 25 度, 你在撒谎
结果形式	$[L, U]$ 连续的区间	拒绝/接受 (拒绝域 W)

易漏点

1. 常见分布的点估计

矩法

① 指数分布 $\mu = E(X) = \frac{1}{\lambda}$ $\lambda = \frac{1}{\mu}$ $\hat{\lambda} = \frac{1}{\bar{X}} = \frac{n}{\sum X_i}$

② 均匀分布 $\begin{cases} \mu = E(X) = \frac{a+b}{2} \\ \sigma^2 = D(X) = \frac{(b-a)^2}{12} \end{cases} \Rightarrow \begin{cases} a = \mu - \sqrt{3}\sigma \\ b = \mu + \sqrt{3}\sigma \end{cases} \Rightarrow \begin{cases} \hat{a} = \bar{X} - \sqrt{3}\hat{\sigma} \\ \hat{b} = \bar{X} + \sqrt{3}\hat{\sigma} \end{cases}$

③ 正态分布 $\begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = A_2 - \bar{X}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 = B_2 \end{cases}$

④ 任意分布 $\begin{cases} E(X) = \mu \\ E(X^2) = \sigma^2 + \mu^2 \end{cases} \Rightarrow \begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = A_2 - \bar{X}^2 = B_2 \end{cases}$ 矩估计不涉及分布

极大似然估计

① 泊松分布 $\lambda = \hat{\lambda} = \bar{X}$

② 正态分布 $\begin{cases} \hat{\mu} = \bar{X} \\ \hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2 \end{cases}$

$L(\lambda) = \prod_{i=1}^n \frac{\lambda^{x_i} e^{-\lambda}}{x_i!} = \frac{e^{-n\lambda} \lambda^{\sum x_i}}{\prod x_i!}$

$\ln L(\lambda) = -n\lambda + (\sum x_i) \ln \lambda - \ln(\prod x_i!)$

$\Rightarrow \frac{dL(\lambda)}{d\lambda} = 0 \Rightarrow \hat{\lambda} = \bar{X}$

$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left[-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right]$

$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$

求导 $\begin{cases} \frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = \frac{1}{\sigma^2} \sum (x_i - \mu) = 0 \\ \frac{\partial \ln L(\mu, \sigma^2)}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2 = 0 \end{cases}$

总结对比表				
分布类型	参数	矩估计 (MoM)	极大似然估计 (MLE)	无偏性 (MLE)
正态	μ, σ^2	$\bar{X}, S^2$	$\bar{X}, S^2$	无偏 (有偏)
泊松	λ	$\bar{X}$	$\bar{X}$	有偏 (渐近无偏)
指数	λ	$1/\bar{X}$	$1/\bar{X}$	有偏 (渐近无偏)
均匀	a, b	$2\bar{X}$	$X_{(n)}$	有偏 (渐近无偏)

核心结论:
 1. MLE 往往有偏 (如正态方差、均匀分布上限), 但通常具备渐近无偏性和渐近有效性 (大样本下表现最佳).
 2. 矩估计通常更直观且容易计算, 在涉及期望时往往是无偏的, 但在方差期望 (有偏性) 上通常不如 MLE. 尤其是在非指数族分布 (如均匀分布) 中表现较差.

4. $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
 $D\left(\frac{(n-1)S^2}{\sigma^2}\right) = 2(n-1) \Rightarrow D(S^2) = \frac{2\sigma^4}{n-1}$

Tip

$\bar{X} \xrightarrow{P} \mu$ $E(\bar{X}) = \mu$ $D(\bar{X}) = \frac{\sigma^2}{n}$
 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2 \xrightarrow{P} \sigma^2$ $E(S^2) = \sigma^2$ $D\left(\frac{(n-1)S^2}{\sigma^2}\right) = 2(n-1)$
 $S_n^2 = \frac{n}{n-1} S^2 \xrightarrow{P} \sigma^2$ $E(S_n^2) = \sigma^2$ $D(S_n^2) = \frac{2\sigma^4}{n-1}$

2. 均方误差

$Mse(\hat{\theta}) = E[(\hat{\theta} - \theta)^2]$ $E(\text{常数}) = \text{常数}$
 $= E[(\hat{\theta} - E(\hat{\theta}) + E(\hat{\theta}) - \theta)^2]$
 $= E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)]$
 $= D(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2 + 2(E(\hat{\theta}) - \theta) E[(\hat{\theta} - E(\hat{\theta}))]$
 $= D(\hat{\theta}) + [E(\hat{\theta}) - \theta]^2$

3. 无偏估计

例 7.2.1 设总体 X 的均值 μ 和方差 σ^2 存在, $X_1, X_2, \dots, X_n$ 是来自总体 X 的样本, 证明:

- 样本均值 $\bar{X}$ 和方差 S^2 分别为 μ 和 σ^2 的无偏估计;
- B_2 是 σ^2 的渐近无偏估计;
- $\mu^* = \sum_{i=1}^n c_i X_i$, 其中权重系数满足 $\sum_{i=1}^n c_i = 1$, μ^* 为 μ 的无偏估计.

μ^* 为 μ 的线性无偏估计

(1) $E(S^2) = \sigma^2$ (2)

证: $E(S^2) = E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \sigma^2$

$(X_i - \bar{X})^2 = [X_i - \mu + (\mu - \bar{X})]^2$
 $= (X_i - \mu)^2 - 2(X_i - \mu)(\bar{X} - \mu) + (\bar{X} - \mu)^2$

$\frac{1}{n-1} \sum (X_i - \bar{X})^2 = \frac{1}{n-1} \sum (X_i - \mu)^2 - n(\bar{X} - \mu)^2$

$E\left[\frac{1}{n-1} \sum (X_i - \bar{X})^2\right] = \frac{1}{n-1} E\left[\sum (X_i - \mu)^2\right] - nE[(\bar{X} - \mu)^2]$

$\therefore E\left[\frac{1}{n-1} \sum (X_i - \bar{X})^2\right] = \sigma^2$

3. 伯努利试验中样本比例 $\hat{p}$ 是概率 p 的无偏估计

背景: n 次独立重复试验, 成功次数为 X , 则 $X \sim B(n, p)$.

结论: $E(\hat{p}) = p$, 其中 $\hat{p} = \frac{X}{n}$.

证明:

已知二项分布的期望 $E(X) = np$.

$E(\hat{p}) = E\left(\frac{X}{n}\right) = \frac{1}{n} E(X) = \frac{1}{n} \cdot np = p$

证明完毕.

4. 均匀分布 $U[0, \theta]$ 中最大观测值的修正估计

背景: 总体服从 $[0, \theta]$ 上的均匀分布. 极大似然估计量 (MLE) 是 $X_{(n)} = \max(X_1, \dots, X_n)$. 但 MLE 在这里是偏估计.

结论: $\hat{\theta} = \frac{n+1}{n} X_{(n)}$ 是 θ 的无偏估计.

证明:

1. 首先求 $X_{(n)}$ 的概率密度函数.

$F_{X_{(n)}}(x) = P(X_i \leq x)^n = \left(\frac{x}{\theta}\right)^n$ (当 $0 \leq x \leq \theta$ 时).

求得密度函数 $f_{X_{(n)}}(x) = \frac{n x^{n-1}}{\theta^n}$.

2. 求 $X_{(n)}$ 的期望:

$E(X_{(n)}) = \int_0^\theta x \cdot \frac{n x^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^\theta x^n dx = \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} = \frac{n}{n+1} \theta$

3. 修正:

显然 $E(X_{(n)}) \neq \theta$, 为了凑出 θ , 我们在前面乘以其倒数.

$E\left(\frac{n+1}{n} X_{(n)}\right) = \frac{n+1}{n} \cdot \frac{n}{n+1} \theta = \theta$

参数	无偏估计量公式	备注
均值 μ	$\bar{X} = \frac{1}{n} \sum X_i$	最常用
方差 σ^2	$S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$	分母必须是 $n-1$
比例 p	$\hat{p} = X/n$	伯努利分布
均匀分布 θ	$\frac{n+1}{n} \max(X_i)$	对 MLE 的修正

易错点

S^2, S_n^2 与 b^2 间无直接关系式
只能用样本去估计总体

1. 严格区分
总体方差 $b^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 = E(X^2) - (E(X))^2$ 有偏
样本 = 阶中心矩 $B_2 = S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum X_i^2 - \bar{X}^2$
(修正) 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} S_n^2$ 无偏

2. 小概率率 α < 显著性水平 α
置信水平 $1-\alpha$

指标	常用值	代表含义	调大的后果
显著性水平 (α)	0.05, 0.01	愿意承担的“报错”风险	容易发现规律, 但容易产生伪阳性。
置信水平 ($1 - \alpha$)	95%, 99%	结论覆盖真值的可靠性	结论更可靠, 但区间变宽, 精确度下降。

3. 样值值的性质

对任何分布的总体有 $E(\bar{X}) = E(X) = \mu$
 $D(\bar{X}) = \frac{1}{n} \sum D(X_i) = \frac{1}{n} n b^2 = \frac{b^2}{n}$ 独立同分布
因为从总体中抽到的样本为独立同分布

若总体 $X \sim N(\mu, b^2)$

则 $\bar{X} \sim N(\mu, \frac{b^2}{n})$

$\bar{X} = \frac{1}{n} \sum X_i$

4. 数字特征的性质对比

一、期望的性质 $E(X)$		
核心特点: 线性。期望的线性性质不需要独立性, 对任何分布都成立。		
性质公式	成立条件	备注
$E(C) = C$	C 是常数	常数的期望是自身
$E(aX + b) = aE(X) + b$	无前提 (任意分布)	线性平移性质
$E(X \pm Y) = E(X) \pm E(Y)$	无前提 (任意分布)	最常用, 不要求独立
$E(XY) = E(X)E(Y)$	X, Y 相互独立	独立则乘积的期望等于期望的乘积
二、方差的性质 $D(X)$ 或 $Var(X)$		
核心特点: 非线性 (二次方关系)。涉及多个变量相加时, 独立性是关键。		
性质公式	成立条件	备注
$D(C) = 0$	C 是常数	常数没有波动
$D(aX + b) = a^2 D(X)$	无前提	常数 b 不影响波动, 系数 a 变平方
$D(X) = E(X^2) - [E(X)]^2$	无前提	方差的计算定义式
$D(X \pm Y) = D(X) + D(Y) \pm 2Cov(X, Y)$	无前提	一般情形的展开式
$D(X \pm Y) = D(X) + D(Y)$	X, Y 相互独立	独立: 减法也是 $D(X) + D(Y)$
$D(\sum_{i=1}^n a_i X_i) = \sum_{i=1}^n a_i^2 D(X_i)$	X_i 两两独立	独立变量线性组合的方差

★ 考试避坑指南 (重点)

- 期望是线性: 公式 $E(X + Y) = E(X) + E(Y)$ 无条件成立。千万不要在填空那里去找独立条件。
- 方差是系数: $D(aX + b) = a^2 D(X) + D(b)$ 也适用。如果没有独立性, 千万不要用了后面那个 $2Cov(X, Y)$ 。
- 方差的加法: 不论 X, Y 是相加还是减, 独立时 $D(X - Y)$ 也是 $D(X) + D(Y)$ 。因为 $(-1)^2 = 1$, 减法是相加。
- 独立与不相关:
 - 独立 $\Rightarrow$ 不相关 ($Cov = 0, \rho = 0$)。
 - 不相关 $\Rightarrow$ 独立 (除非是二维正态分布)。

三、协方差的性质 $Cov(X, Y)$		
核心特点: 双线性。衡量两个变量的相关方向。		
性质公式	成立条件	备注
$Cov(X, Y) = Cov(Y, X)$	无前提	对称性
$Cov(X, X) = D(X)$	无前提	自身协方差等于方差
$Cov(aX, bY) = abCov(X, Y)$	无前提	系数可直接提取
$Cov(X_1 + X_2, Y) = Cov(X_1, Y) + Cov(X_2, Y)$	无前提	分配律
$Cov(X, Y) = E(XY) - E(X)E(Y)$	无前提	计算常用公式
$Cov(X, Y) = 0$	X, Y 相互独立	独立必不相关 (反之不一定)

四、相关系数 ρ_{XY}		
相关系数是标准化的协方差: $\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$		
1. 范围: $ \rho_{XY} \leq 1$ 。		
2. $ \rho_{XY} = 1$ 的充要条件: 存在常数 a, b , 使得 $P(Y = aX + b) = 1$ (即 X, Y 严格线性相关)。		
3. $\rho_{XY} = 0$: 称为 X, Y 不相关 (没有线性关系)。		

✗ 即使 X, Y 相互独立, $D(XY) = D(X)D(Y)$ 也不成立 (除非 $E(X)=E(Y)=0$) $\Rightarrow$ 正解: $D(XY) = E(X^2Y^2) - E(XY)^2 = E(X^2)E(Y^2) - E(X)^2E(Y)^2$

7. 分布的再生性

1. 正态分布的“特权”: 任意线性组合	
正态分布之所以在统计学中地位极高, 是因为它的性质极其稳定:	
- 如果 X, Y 独立且服从正态分布, 那么它们的任何线性组合 $aX + bY + c$ 仍然服从正态分布。 - 它是唯一一种具有这种“全能”线性组合性质的连续分布 (除了退化的常数分布)。	
2. 其他分布的“再生性”: 仅限独立之和	
很多常见的分布也具有类似的性质, 但通常仅限于“独立随机变量之和”, 而不能随意进行乘法或减法运算。这种性质被称为分布的再生性。	
以下是几个典型的例子:	
(1) 泊松分布 $P(\lambda)$ —— 有条件再生	
- 和还是泊松: 如果 $X \sim P(\lambda_1)$ 且 $Y \sim P(\lambda_2)$ 且独立, 那么 $X + Y \sim P(\lambda_1 + \lambda_2)$。 - 线性组合不是: $2X$ 不是泊松分布。泊松分布的取值必须是连续整数 $\{0, 1, 2, \dots\}$, 而 $2X$ 的取值只有偶数 $\{0, 2, 4, \dots\}$, 这显然不符合泊松分布的定义。 $X - Y$ 也不是泊松分布。泊松分布不能取负值。	
(2) 二项分布 $B(n, p)$ —— 有条件再生	
- 和还是二项: 只有当成功概率 p 相同时才行。如果 $X \sim B(n_1, p)$, $Y \sim B(n_2, p)$ 且独立, 那么 $X + Y \sim B(n_1 + n_2, p)$。 - 如果 p 不同, 它们的和就不再是二项分布。	
(3) 卡方分布 $\chi^2(n)$ —— 再生性很好	
- 如果 $X \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$ 且独立, 那么 $X + Y \sim \chi^2(n_1 + n_2)$。 - 这是数理统计中构造 t 分布和 F 分布的基础。	
(4) 指数分布 $E(\lambda)$ —— 不具有再生性	
- 注意! 两个独立的指数分布之和 不再是指数分布, 而是 伽马分布 (Gamma Distribution) 或称 爱尔兰分布 (Erlang Distribution)。 - 这是因为指数分布代表“等待第一个事件的时间”, 两个时间之和自然就变成了“等待两个事件的时间”。	

5. 区分

$D(X) = E[(X - \bar{X})^2] = E(X^2) - E(X)^2$
 $Mse(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = D(\hat{\theta}) + (E\hat{\theta} - \theta)^2$
 $Cov(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$
 $\rho_{XY} = \frac{Cov(X, Y)}{\sqrt{D(X)D(Y)}}$

8. 区分

$P(A|B|C) = P(A|C) + P(B|C) - P(A \cap B|C)$
 $P(C|A \cup B) = \frac{P(C \cap A \cup B)}{P(A \cup B)}$


6. 区分

F $\begin{cases} \max \leq t & F_M(t) = P\{X_1 \leq m\} \dots P\{X_n \leq m\} = [F_X(m)]^n \\ \max > t & 1 - [F_X(t)]^n \\ \min \leq t & F_N(t) = 1 - [1 - F_X(t)]^n \\ \min > t & [1 - F_X(t)]^n \end{cases}$
 f $\begin{cases} \max \leq t & f_M(t) = n[F_X(t)]^{n-1} f_X(t) \\ \max > t & \\ \min \leq t & f_N(t) = n[1 - F_X(t)]^{n-1} f_X(t) \\ \min > t & \end{cases}$

$E(aX + b) = aE(X) + b$ $D(aX + b) = a^2 D(X)$
 $E(\sum X_i) = \sum E(X_i)$ $D(\sum X_i) = \sum D(X_i) + 2 \sum_{i < j} Cov(X_i, X_j)$ 独立 $\Rightarrow D(\sum X_i) = \sum D(X_i)$
 $E(\prod_{i=1}^n X_i) \stackrel{\text{独立}}{=} \prod_{i=1}^n E(X_i)$ $D(\prod_{i=1}^n X_i) = ?$ 用定义 $D(X) = E(X^2) - E(X)^2$
 $E(XY) \stackrel{\text{独立}}{=} E(X)E(Y)$ $D(XY) = E(X^2Y^2) - E(XY)^2 \stackrel{\text{独立}}{=} E(X^2)E(Y^2) - E(X)^2E(Y)^2$
 $Cov(X, Y) = E[(X - E(X))(Y - E(Y))] = E(XY) - E(X)E(Y)$
 $Cov(X, Y) = Cov(Y, X)$
 $Cov(X, X) = D(X)$
 $Cov(aX + b, cY + d) = ac Cov(X, Y)$
 $Cov(X_1 + X_2, Y_1 + Y_2) = Cov(X_1, Y_1) + Cov(X_1, Y_2) + Cov(X_2, Y_1) + Cov(X_2, Y_2)$


分布类型	独立之和 ($X + Y$) 是否服从原分布?	线性组合 ($aX + bY + c$) 是否服从原分布?
正态分布	是	是 (最全能)
泊松分布	是 (参数相加)	否 (倍数和差都不行)
卡方分布	是 (自由度相加)	否
二项分布	是 (前提是 p 相同)	否
指数分布	否 (变为 Gamma 分布)	否
柯西分布	是	是 (它是另一个特例)

知识树



大数定理: $n \rightarrow \infty$ 时的样本均值收敛 统计的合理性 = 可以用样本估计总体
中心极限定理: 用正态分布近似独立同分布 统计的定量计算: 大量样本的均值服从正态分布
故可以定量计算估计的准确度与精度

基础: 统计量 & 抽样分布——枢轴量



求置信区间步骤

我们可以根据下列三个步骤来寻求 θ 的置信区间:

(1) 构造一个分布已知的枢轴量 $G(X_1, X_2, \dots, X_n; \theta)$.

(2) 当总体 X 是连续型随机变量时, 对给定的置信水平 $1 - \alpha$, 根据枢轴量 $G(X_1, X_2, \dots, X_n; \theta)$ 的分布, 适当地选择两个常数 a 和 b , 使

$$P\{a < G(X_1, X_2, \dots, X_n; \theta) < b\} = 1 - \alpha. \quad (7.3.3)$$

(2)' 当总体 X 是离散型随机变量时, 对给定的置信水平 $1 - \alpha$, 选取常数 a 和 b 满足

$$P\{a < G(X_1, X_2, \dots, X_n; \theta) < b\} \geq 1 - \alpha \text{ 且尽可能接近 } 1 - \alpha. \quad (7.3.4)$$

(3) 假如参数 θ 可以从 $G(X_1, X_2, \dots, X_n; \theta)$ 中分离出来, 不等式 $a < G(X_1, X_2, \dots, X_n; \theta) < b$ 可以等价地转化为 $\hat{\theta}_L < \theta < \hat{\theta}_U$, 则对于连续型总体, 由 (7.3.3) 得

$$P\{\hat{\theta}_L < \theta < \hat{\theta}_U\} = 1 - \alpha;$$

对于离散型总体, 由 (7.3.4) 得

$$P\{\hat{\theta}_L < \theta < \hat{\theta}_U\} \geq 1 - \alpha,$$

且尽可能接近 $1 - \alpha$. 这表明 $(\hat{\theta}_L, \hat{\theta}_U)$ 是 θ 的置信水平为 $1 - \alpha$ 的置信区间.

一般地, 满足 (7.3.3) 或 (7.3.4) 的常数 a 和 b 的解是不唯一的. 根据奈曼原则, 我们应该选择使置信区间 $(\hat{\theta}_L, \hat{\theta}_U)$ 的平均长度达到最短的 a 和 b , 但有时要做到这点并非易事. 习惯上, 我们取 a 和 b 满足

$$P_\theta\{G(X_1, X_2, \dots, X_n; \theta) \leq a\} = P_\theta\{G(X_1, X_2, \dots, X_n; \theta) \geq b\} = \frac{\alpha}{2}. \quad (7.3.5)$$

在实际操作中, 枢轴量 $G(X_1, X_2, \dots, X_n; \theta)$ 的构造, 通常会从参数 θ 的点估计出发, 结合估计量的分布, 由估计量改造而得. 在下一节中, 我们将具体介绍如何利用枢轴量法来得到正态总体参数的置信区间.

① 根据已知? 求? 判断用? G

② 枢轴量 G

③ $P\{a < G < b\} = 1 - \alpha$

④ $P\{\theta_L < \theta < \theta_U\} = 1 - \alpha$
 置信区间 (θ_L, θ_U)
 单/双侧置信限

假设检验问题步骤

(1) 根据实际问题提出原假设和备择假设;

(2) 提出检验统计量和拒绝域的形式;

(3) 根据奈曼-皮尔逊原则和给定的显著性水平 α , 求出拒绝域 W 中的临界值;

(4) 根据实际样本值作出判断.

其中步骤 (3), (4) 也可如下进行:

(3)' 计算检验统计量的观测值和 P -值;

(4)' 根据给定的显著性水平 α , 作出判断.

一般的统计分析软件处理假设检验问题都是通过计算 P -值而不是给出拒绝域 W 来作出判断的. 在下面的章节中, 我们将结合两种思想来介绍假设检验问题.

③ 置信区间

① 写假设 H_0, H_1

② 根据已知? 求? 判断用? 检验统计量

③ 拒绝域 W 及其临界

④ 检验统计量取值与 W 比
 算 P 值与 α 比
 单/双侧置信限与 W 比
 } 等价

积分公式

性质一：关于坐标轴对称（最常用）

- 若区域 D 关于 x 轴对称（上下对称）：
 - $\iint_D (\text{关于 } y \text{ 的奇函数}) dx dy = 0$ （如含有 $y, y^3, \sin y$ 等项）
 - $\iint_D (\text{关于 } y \text{ 的偶函数}) dx dy = 2 \iint_{D_+} \dots$
- 若区域 D 关于 y 轴对称（左右对称）：
 - $\iint_D (\text{关于 } x \text{ 的奇函数}) dx dy = 0$ （如含有 $x, x^5, \tan x$ 等项）
 - $\iint_D (\text{关于 } x \text{ 的偶函数}) dx dy = 2 \iint_{D_+} \dots$

性质二：关于直线 $y = x$ 对称（轮换对称性）

如果区域 D 关于 $y = x$ 对称（比如正方形、圆心在原点的圆）：

- $\iint_D f(x, y) dx dy = \iint_D f(y, x) dx dy$
- 这意味着你可以直接交换 x 和 y 。
- 秒杀神技：如果 $f(x, y)$ 满足交换后取负号，积分就是 0。
 - 例如：在单位圆上计算 $\iint_D (x - y) dx dy$ ，因为 x, y 地位平等，结果直接为 0。

性质三：关于原点对称

如果区域 D 关于原点中心对称，且 $f(-x, -y) = -f(x, y)$ ，则积分等于 0。

总结建议：

- 对称性先看区域，再看函数，能变 0 最好。
- 无穷区间（且有 e^{-ax} ）优先想 **Gamma 函数**。
- 0 到 1 区间（多项式乘积）优先想 **Beta 函数**。
- 正态分布相关优先想 **配方法** 凑 PDF 积分为 1。

1. 伽马函数 (Gamma Function) —— 处理指数型积分的神器

在算指数分布、 χ^2 分布或形如 $x^n e^{-ax}$ 的期望时，这个公式可以秒杀分部积分。

- 标准公式： $\Gamma(n) = \int_0^{+\infty} x^{n-1} e^{-x} dx = (n-1)!$
- 考试常用变形（非常重要）：

$$\int_0^{+\infty} x^a e^{-ax} dx = \frac{n!}{a^{n+1}} \quad (a > 0, n \text{ 为正整数})$$

- 特殊值： $\Gamma(\frac{1}{2}) = \sqrt{\pi}$

例：设 $X \sim \text{Exp}(\lambda)$ ，求 $E(X^2)$ 。

你需要算 $\int_0^{+\infty} x^2 \lambda e^{-\lambda x} dx$ 。直接套用： $\lambda \cdot \frac{2!}{\lambda^3} = \frac{2}{\lambda}$ 。

2. 高斯积分 (Gaussian Integral) —— 处理正态分布的核心

当你遇到形如 e^{-ax^2} 的积分时，它是唯一出路。

- 标准型： $\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$
- 概率论常用型： $\int_{-\infty}^{+\infty} e^{-\frac{x^2}{2\sigma^2}} dx = \sqrt{2\pi}\sigma$
- 更广义的形式： $\int_{-\infty}^{+\infty} e^{-ax^2} dx = \sqrt{\frac{\pi}{a}}$

3. 贝塔函数 (Beta Function) —— 处理 [0, 1] 区间幂函数

在处理均匀分布的幕次或者多项式联合分布时非常有用。

- 公式： $B(m, n) = \int_0^1 x^{m-1} (1-x)^{n-1} dx = \frac{(m-1)!(n-1)!}{(m+n-1)!}$
- 应用：如果你遇到 $\int_0^1 x^4 (1-x)^3 dx$ ，不需要展开，直接得 $\frac{4!3!}{6!} = \frac{24 \cdot 6}{720} = \frac{1}{20}$ 。

4. 极坐标变换 —— 处理圆形区域

当积分区域 D 是圆、扇形，或者被积函数含有 $x^2 + y^2$ 时。

- 变换规则： $x = r \cos \theta, y = r \sin \theta$
- 面积元素： $dx dy = r dr d\theta$ （千万别漏掉那个 r ）
- 例： $\iint_{x^2+y^2 \leq R^2} (x^2 + y^2) dx dy = \int_0^{2\pi} d\theta \int_0^R r^2 \cdot r dr = 2\pi \cdot \frac{R^4}{4} = \frac{\pi R^4}{2}$ 。

5. 分部积分的“表格法” (Tabular Integration)

当你必须计算 $\int x^n \sin(ax) dx$ 或 $\int x^n e^{ax} dx$ 时，分部积分写两三次很容易错。

- 方法：
 - 左边一列写多项式 x^n ，逐级求导直到 0。
 - 右边一列写余下部分（如 e^{ax} ），逐级积分。
 - 对角线相连，正负号交替（ $+$ - $+$ - ...）。
 - 这能节省大量检查符号错误的时间。

6. 概率意义法 (降维打击)

这不是积分公式，而是一种思维模式。

如果在计算一个复杂的积分时，发现它的结构长得很像某个概率密度函数（PDF），可以直接利用“密度函数在全空间积分为 1”的性质。

- 例子：计算 $I = \int_{-\infty}^{+\infty} e^{-x^2+2x} dx$ 。
 - 配方： $-x^2 + 2x = -(x-1)^2 + 1$ 。
 - 提常数： $I = e^1 \int_{-\infty}^{+\infty} e^{-(x-1)^2} dx$ 。
 - 看作正态分布：由于 $N(1, 1/2)$ 的密度函数积分是 1，即 $\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi(1/2)}} e^{-\frac{(x-1)^2}{2(1/2)}} dx = 1$ 。
 - 口算得出： $\int_{-\infty}^{+\infty} e^{-(x-1)^2} dx = \sqrt{\pi}$ 。
 - 结果： $I = e\sqrt{\pi}$ 。

$$\left\{ \begin{array}{l} \int_0^{+\infty} x^n e^{-ax} dx = \frac{n!}{a^{n+1}} \\ \int_{-\infty}^{+\infty} e^{-ax^2} dx = \sqrt{\frac{\pi}{a}} \\ \int_0^1 x^{m-1} (1-x)^{n-1} dx = \frac{(m-1)!(n-1)!}{(m+n-1)!} \\ \int_0^{+\infty} e^{-x^2} dx = \frac{\sqrt{\pi}}{2} \\ \int_0^{+\infty} e^{-ax^2} dx = \frac{1}{2} \sqrt{\frac{\pi}{a}} \end{array} \right.$$

例子 1：计算 $\int x^2 \sin x dx$

符号	微分 (D)	积分 (I)
+	x^2	$\sin x$
-	$2x$	$-\cos x$
+	2	$-\sin x$
-	0	$\cos x$

读取结果（按对角线）：

- $(+) \cdot (x^2) \cdot (-\cos x) = -x^2 \cos x$
- $(-) \cdot (2x) \cdot (-\sin x) = +2x \sin x$
- $(+) \cdot (2) \cdot (\cos x) = +2 \cos x$

最终答案：

$$\int x^2 \sin x dx = -x^2 \cos x + 2x \sin x + 2 \cos x + C$$

4. 两种特殊情况

情况 A：D 列无法变为 0（循环型）

例如 $\int e^x \sin x dx$ 。

- 当你发现 D 这一行和 I 这一行的乘积与初始题目成比例时，停止列表。
- 最后一行求导结果，并加上积分号。
- 通过移项解出待求积分。

情况 B： $\ln x$ 或 反三角函数

对于 $\int \ln x dx$ ，通常选 $u = \ln x, dv = 1$ 。

- 虽然 u 的导数不会变 0，但求导后积分往往变得很简单。

例题

题目：产品质量抽检问题

某工厂生产的一种零件，出现次品的概率 $p = 0.05$ 。现在需要对这些零件进行抽样检查，问：至少应抽取多少个零件，才能保证次品出现的频率 $\frac{n_A}{n}$ 与概率 0.05 之差的绝对值小于 0.01 的概率至少为 0.95 ？

简化解答过程：

1. 识别模型与公式：

设 n 为抽取样本量， n_A 为其中的次品数。根据切比雪夫不等式形式的伯努利大数定律结论：

$$P\left(\left|\frac{n_A}{n} - p\right| < \epsilon\right) \geq 1 - \frac{p(1-p)}{n\epsilon^2}$$

2. 代入已知数据：

- 概率 $p = 0.05$
- 允许误差 $\epsilon = 0.01$
- 置信水平（概率值） ≥ 0.95

3. 列式求解：

我们要使：

$$1 - \frac{0.05 \times (1 - 0.05)}{n \times (0.01)^2} \geq 0.95$$

题目 2：切比雪夫不等式与大数定律（进阶题）

设随机变量 $X_1, X_2, \dots, X_n$ 独立同分布，且均值 $E(X_i) = \mu$ ，方差 $D(X_i) = \sigma^2$ 。

问题：

如果我们要保证样本均值 $\bar{X} = \frac{1}{n} \sum X_i$ 与总体均值 μ 的偏离程度 $P(|\bar{X} - \mu| \geq \epsilon)$ 不超过 δ ，根据切比雪夫不等式，样本量 n 至少需要满足什么条件？（用 σ, ϵ, δ 表示）

提示：切比雪夫不等式为 $P(|Y - E(Y)| \geq \epsilon) \leq \frac{D(Y)}{\epsilon^2}$ 。请将 Y 替换为 $\bar{X}$ 。

题目 3：中心极限定理的应用——保险理赔（实战题）

某保险公司有 10,000 名客户。每位客户在一年内出险的概率为 0.02，且各客户出险与否相互独立。如果出险，理赔金额固定为 5,000 元。

问题：

该保险公司一年准备 1,100,000 元的理赔准备金，够用的概率大约是多少？
（已知标准正态分布函数值： $\Phi(2.24) \approx 0.987$, $\Phi(1.58) \approx 0.943$ ）

*提示：

1. 设 X_i 为第 i 个客户的出险金额（0 或 5000）。
2. 计算单个 X_i 的均值 μ 和方差 σ^2 。
3. 利用总和 $S_n = \sum X_i \sim N(n\mu, n\sigma^2)$ 进行计算。*

题目 4：中心极限定理——样本均值的概率（实战题）

某种灯泡的使用寿命从期望为 1000 小时，标准差为 200 小时的指数分布（注：其实什么分布不重要）。现在随机随机抽取 100 只灯泡。

问题：

这 100 只灯泡的平均寿命超过 1040 小时的概率是多少？
（已知标准正态分布函数值： $\Phi(2) = 0.9772$ ）